proyectotalentotec

November 16, 2024

1 Analisis de la Penetracion de Internet Fijo en bogota para el 2024 y 2025

2 Definición

2.1 INTRODUCCION

El objetivo de este proyecto es analizar la penetración de internet fijo en diversas regiones de Colombia utilizando el conjunto de datos de Penetración de Internet Fijo de 2015 a 2023. Los datos incluyen campos como departamentos, municipios, número de accesos a internet fijo, estimaciones de población (DANE) e índices calculados. Nos centraremos en entender las tendencias, las disparidades regionales y las proyecciones futuras, en particular para Bogotá, en los años 2024 y 2025.

Video Explicativo de Youtube

2.2 Descripcion del problema

El principal problema es predecir el crecimiento de los accesos a internet fijo en Bogotá para los años 2024 y 2025. El conjunto de datos proporciona datos históricos que nos ayudarán a identificar patrones de crecimiento de la penetración de internet y a predecir cómo podría cambiar en el futuro. El desafío es utilizar las tendencias históricas, posiblemente combinadas con factores externos como el crecimiento de la población y el desarrollo de la infraestructura tecnológica, para hacer predicciones fiables.

Internet Fijo Penetración Departamentos

Número de suscriptores con acceso fijo a Internet para cada uno de los departamentos de Colombia según los datos reportados por los proveedores al último día de cada trimestre . Basados en estos datos, y en las proyecciones del DANE para la población por departamento, consolidado 2015-4T al 2015 4T, se muestra el porcentaje de penetración de Internet fijo para cada trimestre.

Última Actualización 17 de septiembre de 2024

Datos suministrados por Ministerio de Tecnologías de la Información y las Comunicaciones

---

2.3 Pasos para el análisis de los datos

Limpieza de datos: Verificar que no haya valores nulos o erróneos, especialmente en las columnas de año, trimestre, accesos a internet y población.

Análisis exploratorio de datos (EDA): Observar las tendencias a lo largo del tiempo para distintos departamentos y municipios, analizando cómo ha evolucionado el índice de penetración de internet.

Filtrado de datos: Extraer específicamente los datos de Bogotá para centrarnos en la predicción para esta ciudad.

Análisis de tendencias: Visualizar el crecimiento de los accesos a internet fijo en Bogotá en el período 2022-2023.

Análisis de correlación: Evaluar cómo los accesos a internet fijo están relacionados con el tamaño de la población y otros factores relevantes.

2.4 Enfoque para la predicción 2024-2025

La predicción del crecimiento de los accesos a internet fijo en Bogotá se llevará a cabo utilizando redes neuronales. Las redes neuronales permiten capturar patrones complejos en los datos, lo cual es ideal para identificar tendencias y prever el crecimiento a largo plazo. El enfoque detallado es el siguiente:

- **Preparación de los datos:** Extraer y transformar los datos históricos de Bogotá, y calcular la tasa de crecimiento anual de los accesos a internet fijo.
- **Entrenamiento del modelo:** Entrenar una red neuronal utilizando los datos históricos, para que el modelo aprenda a capturar la tendencia en el.
- **Predicciones:** Utilizar la red neuronal entrenada para proyectar el crecimiento de los accesos a internet fijo en Bogotá para los años 2024 y 2025.

2.5 Técnicas de análisis

- Redes neuronales: La red neuronal será el modelo principal utilizado para la predicción de accesos a internet fijo, dada su capacidad para manejar relaciones no lineales y patrones complejos en los datos.
- Análisis de series de tiempo: Si se cuenta con datos de un período más extenso, podríamos complementar la predicción con métodos de series de tiempo, como ARIMA, para contrastar los resultados de la red neuronal.
- Visualización: Representar gráficamente el crecimiento de los accesos a internet en Bogotá a lo largo del tiempo y proyectar la tendencia para 2024-2025. Comparar visualmente el crecimiento de Bogotá con el de otros municipios clave para observar diferencias regionales.

2.6 Visualizaciones potenciales

- **Gráfico de series temporales:** Mostrar el crecimiento de los accesos a internet fijo en Bogotá durante 2022-2023, incluyendo las proyecciones para 2024-2025 basadas en el modelo de red neuronal.
- **Gráfico de barras:** Comparar el número total de accesos a internet fijo en Bogotá con otros municipios clave, destacando las diferencias en la penetración de internet.

- **Gráfico de tasa de crecimiento:** Visualizar la tasa de crecimiento de los accesos a internet en Bogotá, mostrando el ritmo de cambio a lo largo del tiempo.

2.7 Conclusión

Al finalizar el análisis, se resumirán las tendencias y el escenario futuro basado en las predicciones para 2024-2025, señalando los factores que podrían influir en el crecimiento de los accesos a internet fijo en Bogotá. Además, se discutirá cómo el crecimiento de Bogotá se compara con otras regiones, considerando posibles diferencias en infraestructura y crecimiento poblacional.

3 Desarrollo

3.1 Importación de Librerías

Primero, importaremos las librerías necesarias para el análisis y la predicción de los datos. Vamos a utilizar pandas para la manipulación de datos, matplotlib y seaborn para la visualización, y tensorflow para construir y entrenar la red neuronal.

[2]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
```

Leemos el conjunto de datos y mostramos sus primeras filas para entender su estructura.

[3]:
```
# URL del archivo CSV en formato raw
url = "https://raw.githubusercontent.com/jvergara9208/TalentoTec_Jonathan/main/
 ↪Proyecto/DataSet/Internet_Fijo_Penetraci_n_Municipio_20241019.csv"

# Cargar el archivo en un DataFrame
df_carga = pd.read_csv(url)
data=df_carga.copy()
# Ver las primeras filas del DataFrame
data.head()
```

[3]:

	AÑO	TRIMESTRE	COD_DEPARTAMENTO	DEPARTAMENTO	COD_MUNICIPIO	MUNICIPIO	\
0	2023	2	5	ANTIOQUIA	5353	HISPANIA	
1	2023	1	17	CALDAS	17001	MANIZALES	
2	2023	1	52	NARIÑO	52356	IPIALES	
3	2022	4	27	CHOCÓ	27160	CÉRTEGUI	
4	2022	3	15	BOYACÁ	15740	SIACHOQUE	

	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE

```
0                          495            5790   8,55
1                       102906          454494  22,64
2                        11312          120842   9,36
3                          179            5967   3,00
4                          116            7056   1,64
```

Limpieza De datos

Limpiaremos los datos eliminando valores faltantes y filtrando únicamente la información de Bogotá. Además, convertiremos los datos categóricos a valores numéricos si es necesario.

[4]:
```
# Eliminar valores nulos
data = data.dropna()

# Filtrar datos solo para Bogotá
bogota_data = data[data['DEPARTAMENTO'] == 'BOGOTÁ D.C.']

# Confirmar los datos después del filtro
bogota_data.head()
```

[4]:
```
       AÑO  TRIMESTRE  COD_DEPARTAMENTO DEPARTAMENTO  COD_MUNICIPIO  \
628   2022          4                11  BOGOTÁ D.C.          11001
906   2021          4                11  BOGOTÁ D.C.          11001
917   2022          3                11  BOGOTÁ D.C.          11001
2493  2023          3                11  BOGOTÁ D.C.          11001
6569  2021          3                11  BOGOTÁ D.C.          11001

         MUNICIPIO  No. ACCESOS FIJOS A INTERNET  POBLACIÓN DANE INDICE
628   BOGOTÁ, D.C.                       2269823         7873316  28,83
906   BOGOTÁ, D.C.                       2171274         7823334  27,75
917   BOGOTÁ, D.C.                       2261755         7873316  28,73
2493  BOGOTÁ, D.C.                       2251960         7907281  28,48
6569  BOGOTÁ, D.C.                       2157112         7823334  27,57
```

[5]:
```
# Número de filas y columnas
filas, columnas = bogota_data.shape
print(f"El DataFrame tiene {filas} filas y {columnas} columnas.")
```

```
El DataFrame tiene 32 filas y 9 columnas.
```

[6]:
```
# Ordenar el DataFrame por AÑO y TRIMESTRE
bogota_data = bogota_data.sort_values(by=['AÑO', 'TRIMESTRE'], ascending=[True,␣
 ↪True])

# Mostrar el DataFrame ordenado
bogota_data.head()

# Configuración para mostrar todas las filas
```

```
pd.set_option('display.max_rows', None)

# Mostrar el DataFrame completo
bogota_data
```

[6]:

	AÑO	TRIMESTRE	COD_DEPARTAMENTO	DEPARTAMENTO	COD_MUNICIPIO	\
18771	2015	4	11	BOGOTÁ D.C.	11001	
30907	2016	1	11	BOGOTÁ D.C.	11001	
18047	2016	2	11	BOGOTÁ D.C.	11001	
24086	2016	3	11	BOGOTÁ D.C.	11001	
19515	2016	4	11	BOGOTÁ D.C.	11001	
19722	2017	1	11	BOGOTÁ D.C.	11001	
31959	2017	2	11	BOGOTÁ D.C.	11001	
32574	2017	3	11	BOGOTÁ D.C.	11001	
17650	2017	4	11	BOGOTÁ D.C.	11001	
30078	2018	1	11	BOGOTÁ D.C.	11001	
18810	2018	2	11	BOGOTÁ D.C.	11001	
31062	2018	3	11	BOGOTÁ D.C.	11001	
27540	2018	4	11	BOGOTÁ D.C.	11001	
19157	2019	1	11	BOGOTÁ D.C.	11001	
15798	2019	2	11	BOGOTÁ D.C.	11001	
28073	2019	3	11	BOGOTÁ D.C.	11001	
32490	2019	4	11	BOGOTÁ D.C.	11001	
33078	2020	1	11	BOGOTÁ D.C.	11001	
13832	2020	2	11	BOGOTÁ D.C.	11001	
32350	2020	3	11	BOGOTÁ D.C.	11001	
15648	2020	4	11	BOGOTÁ D.C.	11001	
8018	2021	1	11	BOGOTÁ D.C.	11001	
10290	2021	2	11	BOGOTÁ D.C.	11001	
6569	2021	3	11	BOGOTÁ D.C.	11001	
906	2021	4	11	BOGOTÁ D.C.	11001	
11998	2022	1	11	BOGOTÁ D.C.	11001	
6908	2022	2	11	BOGOTÁ D.C.	11001	
917	2022	3	11	BOGOTÁ D.C.	11001	
628	2022	4	11	BOGOTÁ D.C.	11001	
12251	2023	1	11	BOGOTÁ D.C.	11001	
10346	2023	2	11	BOGOTÁ D.C.	11001	
2493	2023	3	11	BOGOTÁ D.C.	11001	

	MUNICIPIO	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE
18771	BOGOTÁ, D.C.	1610511	7273265	22,14
30907	BOGOTÁ, D.C.	1647186	7300918	22,56
18047	BOGOTÁ, D.C.	1681117	7300918	23,03
24086	BOGOTÁ, D.C.	1719075	7300918	23,55
19515	BOGOTÁ, D.C.	1728459	7300918	23,67
19722	BOGOTÁ, D.C.	2638171	7337449	35,95
31959	BOGOTÁ, D.C.	1776768	7337449	24,22

32574	BOGOTÁ, D.C.	1807827	7337449	24,64
17650	BOGOTÁ, D.C.	1818094	7337449	24,78
30078	BOGOTÁ, D.C.	1826350	7412566	24,64
18810	BOGOTÁ, D.C.	1857309	7412566	25,06
31062	BOGOTÁ, D.C.	1875396	7412566	25,30
27540	BOGOTÁ, D.C.	1876271	7412566	25,31
19157	BOGOTÁ, D.C.	1874506	7592871	24,69
15798	BOGOTÁ, D.C.	1890765	7592871	24,90
28073	BOGOTÁ, D.C.	1915409	7592871	25,23
32490	BOGOTÁ, D.C.	1916910	7592871	25,25
33078	BOGOTÁ, D.C.	1957333	7732161	25,31
13832	BOGOTÁ, D.C.	2025140	7732161	26,19
32350	BOGOTÁ, D.C.	2069115	7732161	26,76
15648	BOGOTÁ, D.C.	2088680	7732161	27,01
8018	BOGOTÁ, D.C.	2139304	7823334	27,35
10290	BOGOTÁ, D.C.	2165658	7823334	27,68
6569	BOGOTÁ, D.C.	2157112	7823334	27,57
906	BOGOTÁ, D.C.	2171274	7823334	27,75
11998	BOGOTÁ, D.C.	2240695	7873316	28,46
6908	BOGOTÁ, D.C.	2248809	7873316	28,56
917	BOGOTÁ, D.C.	2261755	7873316	28,73
628	BOGOTÁ, D.C.	2269823	7873316	28,83
12251	BOGOTÁ, D.C.	2298520	7907281	29,07
10346	BOGOTÁ, D.C.	2303696	7907281	29,13
2493	BOGOTÁ, D.C.	2251960	7907281	28,48

uniremos las columnas de trimestre y año

para combinar las columnas AÑO y TRIMESTRE en una sola columna, vamos a usar el método .astype(str) para convertir ambos valores en texto y luego concatenarlos. Esto te permitirá crear una columna con un formato como AÑO-TRIMESTRE (por ejemplo, 2022-4).

[7]:
```
# Crear una nueva columna combinando AÑO y TRIMESTRE como número
bogota_data['AÑO_TRIMESTRE'] = bogota_data['AÑO'].astype(str) +␣
 ↪bogota_data['TRIMESTRE'].apply(lambda x: f"{x:02d}")

# Opcional: eliminar las columnas originales
bogota_data = bogota_data.drop(columns=['AÑO', 'TRIMESTRE'])

# Convertir la columna AÑO_TRIMESTRE a entero
bogota_data['AÑO_TRIMESTRE'] = bogota_data['AÑO_TRIMESTRE'].astype(int)

# Reordenar las columnas para que AÑO_TRIMESTRE esté al principio
cols = ['AÑO_TRIMESTRE'] + [col for col in bogota_data.columns if col !=␣
 ↪'AÑO_TRIMESTRE']
bogota_data = bogota_data[cols]

# Ver el DataFrame actualizado
```

```
bogota_data.head()
```

[7]:
```
       AÑO_TRIMESTRE  COD_DEPARTAMENTO DEPARTAMENTO  COD_MUNICIPIO  \
18771         201504                11  BOGOTÁ D.C.          11001
30907         201601                11  BOGOTÁ D.C.          11001
18047         201602                11  BOGOTÁ D.C.          11001
24086         201603                11  BOGOTÁ D.C.          11001
19515         201604                11  BOGOTÁ D.C.          11001

          MUNICIPIO  No. ACCESOS FIJOS A INTERNET  POBLACIÓN DANE INDICE
18771  BOGOTÁ, D.C.                       1610511         7273265  22,14
30907  BOGOTÁ, D.C.                       1647186         7300918  22,56
18047  BOGOTÁ, D.C.                       1681117         7300918  23,03
24086  BOGOTÁ, D.C.                       1719075         7300918  23,55
19515  BOGOTÁ, D.C.                       1728459         7300918  23,67
```

[8]:
```
# Configuración para mostrar todas las filas
pd.set_option('display.max_rows', None)

# Mostrar el DataFrame completo
bogota_data
```

[8]:
```
       AÑO_TRIMESTRE  COD_DEPARTAMENTO DEPARTAMENTO  COD_MUNICIPIO  \
18771         201504                11  BOGOTÁ D.C.          11001
30907         201601                11  BOGOTÁ D.C.          11001
18047         201602                11  BOGOTÁ D.C.          11001
24086         201603                11  BOGOTÁ D.C.          11001
19515         201604                11  BOGOTÁ D.C.          11001
19722         201701                11  BOGOTÁ D.C.          11001
31959         201702                11  BOGOTÁ D.C.          11001
32574         201703                11  BOGOTÁ D.C.          11001
17650         201704                11  BOGOTÁ D.C.          11001
30078         201801                11  BOGOTÁ D.C.          11001
18810         201802                11  BOGOTÁ D.C.          11001
31062         201803                11  BOGOTÁ D.C.          11001
27540         201804                11  BOGOTÁ D.C.          11001
19157         201901                11  BOGOTÁ D.C.          11001
15798         201902                11  BOGOTÁ D.C.          11001
28073         201903                11  BOGOTÁ D.C.          11001
32490         201904                11  BOGOTÁ D.C.          11001
33078         202001                11  BOGOTÁ D.C.          11001
13832         202002                11  BOGOTÁ D.C.          11001
32350         202003                11  BOGOTÁ D.C.          11001
15648         202004                11  BOGOTÁ D.C.          11001
8018          202101                11  BOGOTÁ D.C.          11001
10290         202102                11  BOGOTÁ D.C.          11001
6569          202103                11  BOGOTÁ D.C.          11001
```

906	202104	11	BOGOTÁ D.C.	11001
11998	202201	11	BOGOTÁ D.C.	11001
6908	202202	11	BOGOTÁ D.C.	11001
917	202203	11	BOGOTÁ D.C.	11001
628	202204	11	BOGOTÁ D.C.	11001
12251	202301	11	BOGOTÁ D.C.	11001
10346	202302	11	BOGOTÁ D.C.	11001
2493	202303	11	BOGOTÁ D.C.	11001

	MUNICIPIO	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE
18771	BOGOTÁ, D.C.	1610511	7273265	22,14
30907	BOGOTÁ, D.C.	1647186	7300918	22,56
18047	BOGOTÁ, D.C.	1681117	7300918	23,03
24086	BOGOTÁ, D.C.	1719075	7300918	23,55
19515	BOGOTÁ, D.C.	1728459	7300918	23,67
19722	BOGOTÁ, D.C.	2638171	7337449	35,95
31959	BOGOTÁ, D.C.	1776768	7337449	24,22
32574	BOGOTÁ, D.C.	1807827	7337449	24,64
17650	BOGOTÁ, D.C.	1818094	7337449	24,78
30078	BOGOTÁ, D.C.	1826350	7412566	24,64
18810	BOGOTÁ, D.C.	1857309	7412566	25,06
31062	BOGOTÁ, D.C.	1875396	7412566	25,30
27540	BOGOTÁ, D.C.	1876271	7412566	25,31
19157	BOGOTÁ, D.C.	1874506	7592871	24,69
15798	BOGOTÁ, D.C.	1890765	7592871	24,90
28073	BOGOTÁ, D.C.	1915409	7592871	25,23
32490	BOGOTÁ, D.C.	1916910	7592871	25,25
33078	BOGOTÁ, D.C.	1957333	7732161	25,31
13832	BOGOTÁ, D.C.	2025140	7732161	26,19
32350	BOGOTÁ, D.C.	2069115	7732161	26,76
15648	BOGOTÁ, D.C.	2088680	7732161	27,01
8018	BOGOTÁ, D.C.	2139304	7823334	27,35
10290	BOGOTÁ, D.C.	2165658	7823334	27,68
6569	BOGOTÁ, D.C.	2157112	7823334	27,57
906	BOGOTÁ, D.C.	2171274	7823334	27,75
11998	BOGOTÁ, D.C.	2240695	7873316	28,46
6908	BOGOTÁ, D.C.	2248809	7873316	28,56
917	BOGOTÁ, D.C.	2261755	7873316	28,73
628	BOGOTÁ, D.C.	2269823	7873316	28,83
12251	BOGOTÁ, D.C.	2298520	7907281	29,07
10346	BOGOTÁ, D.C.	2303696	7907281	29,13
2493	BOGOTÁ, D.C.	2251960	7907281	28,48

eliminaremos las columnas COD_DEPARTAMENTO, COD_MUNICIPIO, DEPARTAMENTO y MUNICIPIO usaremos el método .drop() en pandas, especificando los nombres de las columnas, ya que estas no nos proporciona una informacion relevante.

ACLARACIÓN:

toda la información se ha filtrado para entender que es bogotá toda la información

[9]:
```
# Eliminar las columnas COD_DEPARTAMENTO, COD_MUNICIPIO, MUNICIPIO, DEPARTAMENTO
bogota_data = bogota_data.drop(columns=['COD_DEPARTAMENTO', 'COD_MUNICIPIO',␣
 ↪'DEPARTAMENTO','MUNICIPIO'])

# Ver el DataFrame actualizado
bogota_data.head()
```

[9]:

	AÑO_TRIMESTRE	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE
18771	201504	1610511	7273265	22,14
30907	201601	1647186	7300918	22,56
18047	201602	1681117	7300918	23,03
24086	201603	1719075	7300918	23,55
19515	201604	1728459	7300918	23,67

renombramos la columna indice por INDICE a INDICE(%)

[10]:
```
# Renombrar la columna INDICE a INDICE(%)
bogota_data = bogota_data.rename(columns={'INDICE': 'INDICE(%)'})

# Ver el DataFrame actualizado
# Configuración para mostrar todas las filas
pd.set_option('display.max_rows', None)

# Mostrar el DataFrame completo
bogota_data
```

[10]:

	AÑO_TRIMESTRE	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE(%)
18771	201504	1610511	7273265	22,14
30907	201601	1647186	7300918	22,56
18047	201602	1681117	7300918	23,03
24086	201603	1719075	7300918	23,55
19515	201604	1728459	7300918	23,67
19722	201701	2638171	7337449	35,95
31959	201702	1776768	7337449	24,22
32574	201703	1807827	7337449	24,64
17650	201704	1818094	7337449	24,78
30078	201801	1826350	7412566	24,64
18810	201802	1857309	7412566	25,06
31062	201803	1875396	7412566	25,30
27540	201804	1876271	7412566	25,31
19157	201901	1874506	7592871	24,69
15798	201902	1890765	7592871	24,90
28073	201903	1915409	7592871	25,23
32490	201904	1916910	7592871	25,25
33078	202001	1957333	7732161	25,31
13832	202002	2025140	7732161	26,19

32350	202003	2069115	7732161	26,76
15648	202004	2088680	7732161	27,01
8018	202101	2139304	7823334	27,35
10290	202102	2165658	7823334	27,68
6569	202103	2157112	7823334	27,57
906	202104	2171274	7823334	27,75
11998	202201	2240695	7873316	28,46
6908	202202	2248809	7873316	28,56
917	202203	2261755	7873316	28,73
628	202204	2269823	7873316	28,83
12251	202301	2298520	7907281	29,07
10346	202302	2303696	7907281	29,13
2493	202303	2251960	7907281	28,48

[11]:
```
# Guardar el DataFrame actualizado en un archivo CSV
bogota_data.to_csv('bogota_data_actualizado.csv', index=False)

# Descargar el archivo CSV generado
from google.colab import files
files.download('bogota_data_actualizado.csv')
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.Javascript object>
```

[12]:
```
# Convertir "INDICE(%)" a formato numérico, reemplazando la coma por un punto␣
 ↪decimal
bogota_data['INDICE(%)'] = bogota_data['INDICE(%)'].str.replace(',', '.').
 ↪astype(float)

# Crear histogramas para las columnas numéricas
plt.figure(figsize=(15, 5))

# Histograma para "No. ACCESOS FIJOS A INTERNET"
plt.subplot(1, 3, 1)
sns.histplot(bogota_data['No. ACCESOS FIJOS A INTERNET'], bins=10, kde=True)
plt.title('Distribución de No. ACCESOS FIJOS A INTERNET')
plt.xlabel('Accesos Fijos a Internet')
plt.ylabel('Frecuencia')

# Histograma para "POBLACIÓN DANE"
plt.subplot(1, 3, 2)
sns.histplot(bogota_data['POBLACIÓN DANE'], bins=10, kde=True)
plt.title('Distribución de POBLACIÓN DANE')
plt.xlabel('Población DANE')
plt.ylabel('Frecuencia')
```

```
# Histograma para "INDICE(%)"
plt.subplot(1, 3, 3)
sns.histplot(bogota_data['INDICE(%)'], bins=10, kde=True)
plt.title('Distribución de INDICE(%)')
plt.xlabel('Índice (%)')
plt.ylabel('Frecuencia')

# Mostrar los gráficos
plt.tight_layout()
plt.show()
```

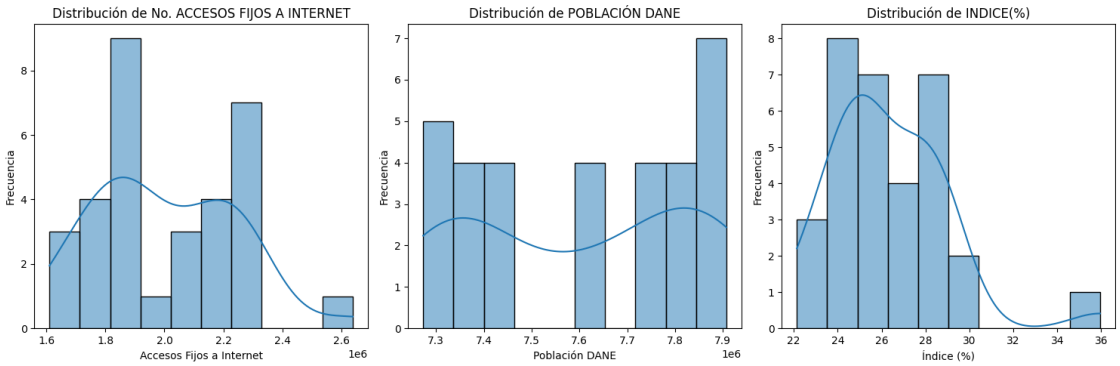

[13]:
```
#bogota_data = pd.read_csv('bogota_data_actualizado.csv')

# Convertir AÑO_TRIMESTRE a string para ordenarlo correctamente en el gráfico
bogota_data['AÑO_TRIMESTRE'] = bogota_data['AÑO_TRIMESTRE'].astype(str)

# Ordenar por AÑO_TRIMESTRE para asegurar la secuencia temporal correcta
bogota_data = bogota_data.sort_values(by='AÑO_TRIMESTRE')

# Crear el gráfico de líneas
plt.figure(figsize=(12, 6))
plt.plot(bogota_data['AÑO_TRIMESTRE'], bogota_data['POBLACIÓN DANE'],␣
 ↪marker='o', linestyle='-', color='b')
plt.title('Evolución de la Población DANE por Trimestre')
plt.xlabel('AÑO_TRIMESTRE')
plt.ylabel('POBLACIÓN DANE')

# Etiquetas para cada punto del gráfico con el valor completo
for i, (x, y) in enumerate(zip(bogota_data['AÑO_TRIMESTRE'],␣
 ↪bogota_data['POBLACIÓN DANE'])):
    plt.text(x, y, f'{int(y):,}', ha='center', va='bottom', fontsize=8,␣
 ↪rotation=45)
```

```
# Personalizar el eje x solo con los trimestres presentes en los datos
plt.xticks(ticks=range(len(bogota_data)), labels=bogota_data['AÑO_TRIMESTRE'],␣
 ↪rotation=45)

plt.grid(True)
plt.tight_layout()
plt.show()
```

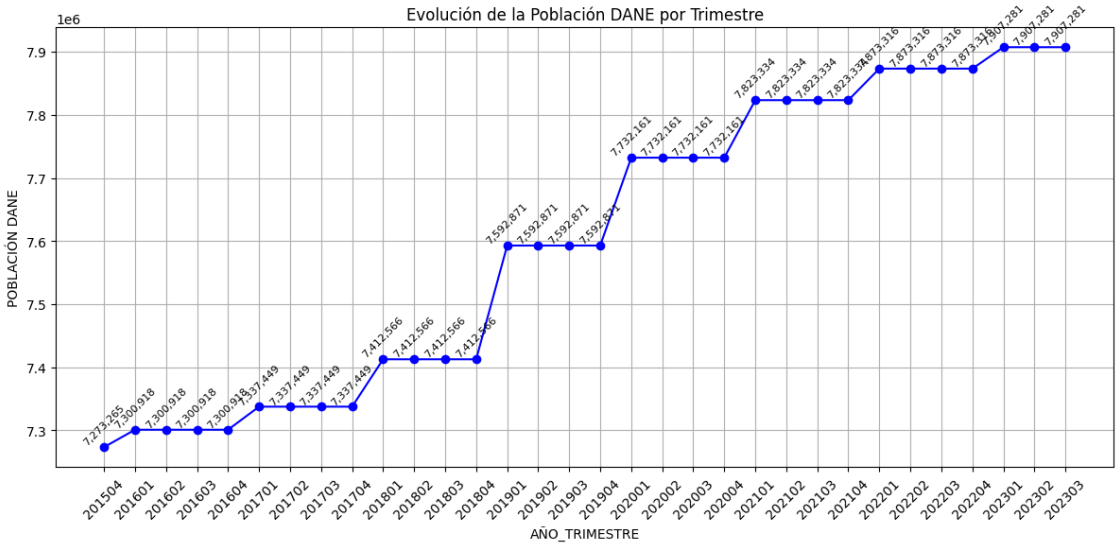

[14]:
```
#bogota_data = pd.read_csv('bogota_data_actualizado.csv')

# Convertir AÑO_TRIMESTRE a string para ordenar correctamente en el gráfico
bogota_data['AÑO_TRIMESTRE'] = bogota_data['AÑO_TRIMESTRE'].astype(str)

# Ordenar por AÑO_TRIMESTRE para asegurar la secuencia temporal correcta
bogota_data = bogota_data.sort_values(by='AÑO_TRIMESTRE')

# Configurar la figura
plt.figure(figsize=(12, 6))

# Graficar la Población DANE en azul
plt.plot(bogota_data['AÑO_TRIMESTRE'], bogota_data['POBLACIÓN DANE'],␣
 ↪marker='o', linestyle='-', color='b', label='Población DANE')

# Graficar los Accesos Fijos a Internet en rojo
plt.plot(bogota_data['AÑO_TRIMESTRE'], bogota_data['No. ACCESOS FIJOS A␣
 ↪INTERNET'], marker='o', linestyle='-', color='r', label='Accesos Fijos a␣
 ↪Internet')
```

```
# Añadir título y etiquetas
plt.title('Evolución de la Población DANE y Accesos Fijos a Internet por Trimestre')
plt.xlabel('AÑO_TRIMESTRE')
plt.ylabel('Cantidad')

# Etiquetas para cada punto de la Población DANE
for x, y in zip(bogota_data['AÑO_TRIMESTRE'], bogota_data['POBLACIÓN DANE']):
    plt.text(x, y, f'{int(y):,}', ha='center', va='bottom', fontsize=8, rotation=45, color='blue')

# Etiquetas para cada punto de Accesos Fijos a Internet
for x, y in zip(bogota_data['AÑO_TRIMESTRE'], bogota_data['No. ACCESOS FIJOS A INTERNET']):
    plt.text(x, y, f'{int(y):,}', ha='center', va='top', fontsize=8, rotation=45, color='red')

# Mostrar la leyenda debajo del gráfico
plt.legend(loc='upper center', bbox_to_anchor=(0.5, -0.15), ncol=2)

# Configurar límites y cuadrícula
plt.ylim(0, 10000000)  # Limitar el eje Y hasta 10 millones
plt.grid(axis='y', linestyle='--', alpha=0.7)  # Cuadrícula solo en el eje Y

# Personalizar el eje x solo con los trimestres presentes en los datos
plt.xticks(ticks=range(len(bogota_data)), labels=bogota_data['AÑO_TRIMESTRE'], rotation=45)

# Activar cuadrícula
plt.tight_layout()
plt.show()
```

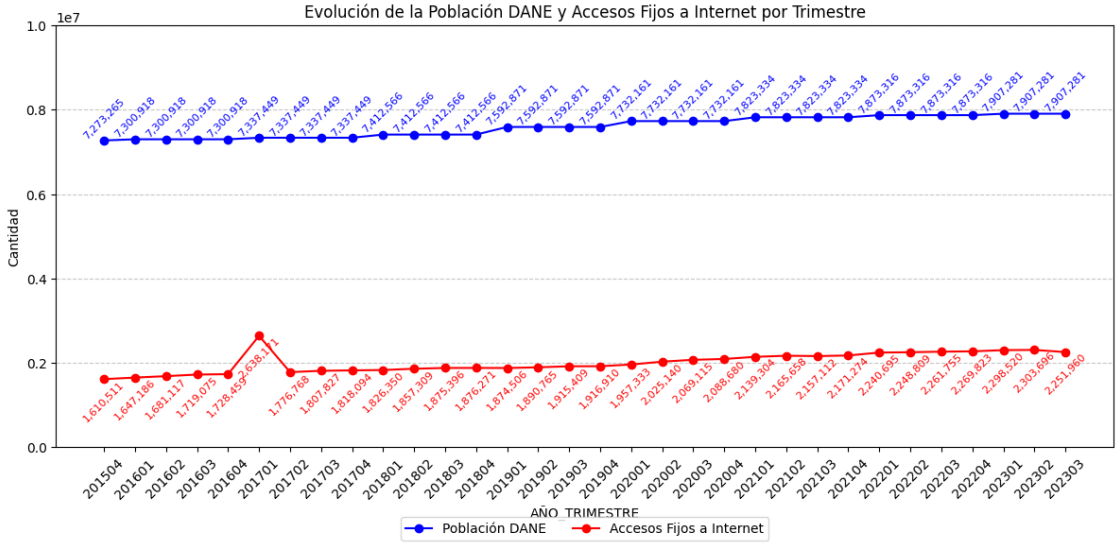

[14]:

[15]:
```
import seaborn as sns

# Histograma para "POBLACIÓN DANE" en millones
plt.figure(figsize=(8, 6))
sns.histplot(bogota_data['POBLACIÓN DANE'], bins=10, kde=True, color='c')
plt.title('Distribución de la Población DANE en Millones')
plt.xlabel('POBLACIÓN DANE (Millones)')
plt.ylabel('Frecuencia')
plt.show()
```

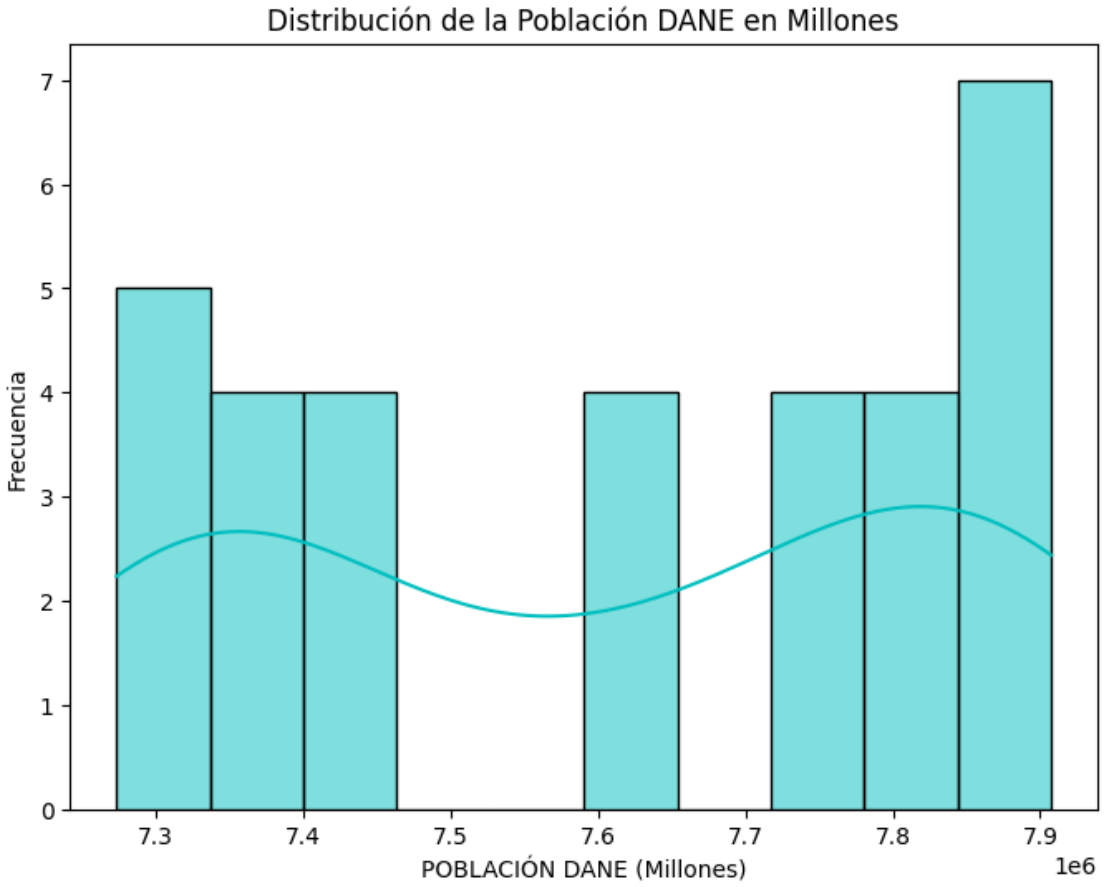

Ahora se comprobara cuantos datos y de que periodos faltan

[16]:
```
# A continuación, se define la función para encontrar trimestres faltantes

def encontrar_trimestres_faltantes(data, anio_inicial, anio_final):
```

```
    faltantes = []
    # Convertir la columna a string
    data['AÑO_TRIMESTRE'] = data['AÑO_TRIMESTRE'].astype(str)

    # Iterar sobre cada año en el rango
    for anio in range(anio_inicial, anio_final + 1):
        # Crear un conjunto con los trimestres esperados para el año actual
        trimestres_esperados = {f"{anio}0{t}" for t in range(1, 5)}
        # Filtrar los trimestres presentes en el DataFrame para el año actual
        trimestres_presentes = set(data[data['AÑO_TRIMESTRE'].str.
 ↪startswith(str(anio))]['AÑO_TRIMESTRE'])
        # Calcular los trimestres faltantes comparando con los esperados
        trimestres_faltantes = trimestres_esperados - trimestres_presentes
        # Agregar los trimestres faltantes a la lista
        faltantes.extend(sorted(trimestres_faltantes))

    return faltantes

# Usar la función con los años inicial y final
anio_inicial = 2015
anio_final = 2025
trimestres_faltantes = encontrar_trimestres_faltantes(bogota_data,␣
 ↪anio_inicial, anio_final)

# Mostrar los trimestres faltantes
print(trimestres_faltantes)
```

```
['201501', '201502', '201503', '202304', '202401', '202402', '202403', '202404',
'202501', '202502', '202503', '202504']
```

Para calcular el índice de penetración de internet, podemos partir de la fórmula común para este tipo de análisis, que relaciona el número de accesos a internet con la población. El índice suele calcularse como:

$$\text{ÍNDICE} = \left(\frac{\text{No. de Accesos Fijos a Internet}}{\text{Población DANE}} \right) \times 100$$

Si tu dataset incluye los campos **No. de Accesos Fijos a Internet** y **Población DANE**, puedes aplicar esta fórmula a cada fila para comparar el índice calculado con el índice que está en el archivo.

En resumen, la comparación del índice calculado con el índice existente nos permitirá:

- Validar la precisión de los datos.
- los estándares utilizados.
- Mejorar la fiabilidad de las predicciones.
- Detectar posibles errores o inconsistencias que deban corregirse.

3.1.1 Paso para el cálculo y comparación del índice

Primero, carga el archivo actualizado, calcula el índice y verifica si coincide con el índice que está en la columna existente.

[17]:
```
# Crear una copia del DataFrame bogota_data
bogota_data_comparar = bogota_data.copy()
bogota_data_comparar.head()
```

[17]:

	AÑO_TRIMESTRE	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE(%)
18771	201504	1610511	7273265	22.14
30907	201601	1647186	7300918	22.56
18047	201602	1681117	7300918	23.03
24086	201603	1719075	7300918	23.55
19515	201604	1728459	7300918	23.67

[18]:
```
# Calcular el índice de penetración en la copia
bogota_data_comparar['ÍNDICE Calculado'] = (bogota_data_comparar['No. ACCESOS␣
 ↪FIJOS A INTERNET'] / bogota_data_comparar['POBLACIÓN DANE']) * 100

# Determinar si el índice calculado coincide con el índice existente
bogota_data_comparar['Coincide'] = bogota_data_comparar['ÍNDICE Calculado'].
 ↪round(2) == bogota_data_comparar['INDICE(%)'].round(2)

# Imprimir el DataFrame comparativo con columnas relevantes
bogota_data_comparar[['AÑO_TRIMESTRE', 'No. ACCESOS FIJOS A INTERNET',␣
 ↪'POBLACIÓN DANE', 'INDICE(%)', 'ÍNDICE Calculado', 'Coincide']]
```

[18]:

	AÑO_TRIMESTRE	No. ACCESOS FIJOS A INTERNET	POBLACIÓN DANE	INDICE(%)	\
18771	201504	1610511	7273265	22.14	
30907	201601	1647186	7300918	22.56	
18047	201602	1681117	7300918	23.03	
24086	201603	1719075	7300918	23.55	
19515	201604	1728459	7300918	23.67	
19722	201701	2638171	7337449	35.95	
31959	201702	1776768	7337449	24.22	
32574	201703	1807827	7337449	24.64	
17650	201704	1818094	7337449	24.78	
30078	201801	1826350	7412566	24.64	
18810	201802	1857309	7412566	25.06	
31062	201803	1875396	7412566	25.30	
27540	201804	1876271	7412566	25.31	
19157	201901	1874506	7592871	24.69	
15798	201902	1890765	7592871	24.90	
28073	201903	1915409	7592871	25.23	
32490	201904	1916910	7592871	25.25	
33078	202001	1957333	7732161	25.31	
13832	202002	2025140	7732161	26.19	
32350	202003	2069115	7732161	26.76	
15648	202004	2088680	7732161	27.01	
8018	202101	2139304	7823334	27.35	
10290	202102	2165658	7823334	27.68	

6569	202103		2157112	7823334	27.57
906	202104		2171274	7823334	27.75
11998	202201		2240695	7873316	28.46
6908	202202		2248809	7873316	28.56
917	202203		2261755	7873316	28.73
628	202204		2269823	7873316	28.83
12251	202301		2298520	7907281	29.07
10346	202302		2303696	7907281	29.13
2493	202303		2251960	7907281	28.48

	ÍNDICE	Calculado	Coincide
18771		22.142889	True
30907		22.561355	True
18047		23.026104	True
24086		23.546012	True
19515		23.674543	True
19722		35.954880	True
31959		24.215064	True
32574		24.638359	True
17650		24.778285	True
30078		24.638566	True
18810		25.056222	True
31062		25.300227	True
27540		25.312031	True
19157		24.687710	True
15798		24.901845	True
28073		25.226413	True
32490		25.246182	True
33078		25.314178	True
13832		26.191126	True
32350		26.759854	True
15648		27.012888	True
8018		27.345170	True
10290		27.682034	True
6569		27.572797	True
906		27.753820	True
11998		28.459356	True
6908		28.562413	True
917		28.726841	True
628		28.829314	True
12251		29.068399	True
10346		29.133858	True
2493		28.479575	True

4 Explicación: Viabilidad de la Regresión Lineal para la Predicción de Accesos a Internet Fijo

En este proyecto, queremos predecir los accesos a internet fijo en Bogotá para varios trimestres faltantes, incluyendo proyecciones para los años 2024 y 2025. A continuación se analiza si el uso de una regresión lineal es viable para esta predicción.

4.1 1. Comportamiento Lineal de los Datos

La regresión lineal es un modelo que asume una relación lineal entre las variables independientes (en este caso, año_trimestre) y la variable dependiente (número de accesos a internet fijo). Este tipo de modelo puede ser adecuado si el crecimiento de los accesos a internet muestra una tendencia constante a lo largo del tiempo, sin grandes variaciones o cambios acelerados.

4.2 2. Dinámica de Crecimiento en el Tiempo

Observando los datos recientes de accesos a internet fijo en Bogotá, es importante analizar si el crecimiento en estos últimos trimestres sigue un patrón lineal o si muestra aceleraciones o desaceleraciones. Si el crecimiento de los accesos ha sido constante, una regresión lineal podría capturar bien la tendencia. Sin embargo, en muchos casos relacionados con tecnología y acceso a servicios, el crecimiento puede no ser lineal, mostrando una tendencia exponencial o cambios bruscos en la expansión de infraestructura.

4.3 3. Predictibilidad a Largo Plazo

Para predecir varios trimestres en el futuro, hasta 2025, la regresión lineal podría ser viable para obtener una primera aproximación, pero no siempre es la más precisa en el largo plazo. Esto se debe a que la regresión lineal puede subestimar o sobreestimar el crecimiento si el ritmo cambia. En estos casos, los modelos de series de tiempo o incluso redes neuronales pueden capturar mejor patrones complejos y cambios en la tendencia.

4.4 Conclusión: Uso de la Regresión Lineal en el Proyecto

Dado que tenemos datos de accesos hasta 2023, una regresión lineal inicial puede ser útil como primera aproximación. Sin embargo, es importante evaluar su precisión y considerar alternativas si los datos muestran variaciones importantes.

4.5 Próximos Pasos para Evaluar la Precisión de la Regresión Lineal

Para determinar si la regresión lineal es suficiente para nuestras predicciones, realizaremos los siguientes pasos:

1. **Implementar una Regresión Lineal Inicial**: Aplicaremos la regresión lineal en los datos históricos para obtener una predicción de los trimestres faltantes.
2. **Calcular las Métricas de Precisión**: Usaremos métricas de precisión como el Error Cuadrático Medio (MSE), el Error Absoluto Medio (MAE) y el R^2 (coeficiente de determinación) para evaluar la exactitud del modelo lineal. Estas métricas nos permitirán cuantificar la diferencia entre las predicciones y los valores reales.
3. **Comparar con Alternativas**: En caso de que el error de la regresión lineal sea significativo, podemos comparar este modelo con otros enfoques, como modelos de series temporales

(ARIMA) o redes neuronales. Esto nos permitirá seleccionar el modelo que mejor se adapte a la dinámica de crecimiento en Bogotá.

4. **Evaluar el Modelo a Corto y Largo Plazo**: Es posible que el modelo de regresión lineal sea suficientemente preciso para el corto plazo (2023-2024) pero no para predicciones más avanzadas. Evaluaremos la precisión en distintos períodos y ajustaremos el modelo si es necesario.

A continuación, implementaremos estos pasos para verificar si la regresión lineal es adecuada para el proyecto.

4.6 Interpretación de los Resultados

- **Error Cuadrático Medio (MSE) y Error Absoluto Medio (MAE)**: Valores bajos de estas métricas indican que el modelo lineal se ajusta bien a los datos históricos.
- **Coeficiente de Determinación (R^2)**: Un valor de R^2 cercano a 1 indica que la regresión lineal explica bien la variabilidad en los accesos a internet.

Si las métricas muestran que el error es aceptable, la regresión lineal puede ser suficiente para las predicciones. Si el error es alto, podríamos probar modelos de series de tiempo o redes neuronales para mejorar la precisión.

[19]:
```
# hacemos esto para enteneder que debemos trasformar para nuestra regresion Lineal
bogota_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 32 entries, 18771 to 2493
Data columns (total 4 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   AÑO_TRIMESTRE                 32 non-null     object
 1   No. ACCESOS FIJOS A INTERNET  32 non-null     int64
 2   POBLACIÓN DANE                32 non-null     int64
 3   INDICE(%)                     32 non-null     float64
dtypes: float64(1), int64(2), object(1)
memory usage: 1.2+ KB
```

[20]:
```
# cargamos la libreria para el analisis

from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
import matplotlib.pyplot as plt
```

[21]:
```
# Crear una copia del DataFrame original con un nombre específico
linear_penetracion_internet = bogota_data.copy()

# Crear la columna 'AÑO_TRIMESTRE_num' convirtiendo 'AÑO_TRIMESTRE' en una variable numérica
```

```
linear_penetracion_internet['AÑO_TRIMESTRE_num'] =␣
 ↪linear_penetracion_internet['AÑO_TRIMESTRE'].apply(lambda x: int(x[:4]) * 10␣
 ↪+ int(x[4:]))
# Regresión 1: Año-Trimestre vs. Número de Accesos
X = linear_penetracion_internet[['AÑO_TRIMESTRE_num']]
y = linear_penetracion_internet['No. ACCESOS FIJOS A INTERNET']

model1 = LinearRegression()
model1.fit(X, y)
y_pred1 = model1.predict(X)

# Calcular métricas de precisión para el primer modelo
mse1 = mean_squared_error(y, y_pred1)
mae1 = mean_absolute_error(y, y_pred1)
r2_1 = r2_score(y, y_pred1)

print("Métricas del primer modelo No. ACCESOS FIJOS A INTERNET:")
print(f"MSE: {mse1:.2f}")
print(f"MAE: {mae1:.2f}")
print(f"R²: {r2_1:.2f}")

# Regresión 2: Año-Trimestre vs. Población DANE
X2 = linear_penetracion_internet[['AÑO_TRIMESTRE_num']]
y2 = linear_penetracion_internet['POBLACIÓN DANE']

model2 = LinearRegression()
model2.fit(X2, y2)
y_pred2 = model2.predict(X2)


# Calcular métricas de precisión para el segundo modelo
mse2 = mean_squared_error(y2, y_pred2)
mae2 = mean_absolute_error(y2, y_pred2)
r2_2 = r2_score(y2, y_pred2)

print("\nMétricas del segundo modelo: POBLACIÓN DANE")
print(f"MSE: {mse2:.2f}")
print(f"MAE: {mae2:.2f}")
print(f"R²: {r2_2:.2f}")

# Visualizaciones
plt.figure(figsize=(12, 6))

# Gráfico 1: Número de Accesos
plt.subplot(1, 2, 1)
plt.plot(X, y, label='Datos Reales', marker='o')
plt.plot(X, y_pred1, label='Predicción', linestyle='--')
```

```
plt.xlabel('Año-Trimestre')
plt.ylabel('Número de Accesos Fijos a Internet')
plt.title('Predicción de Accesos a Internet')
plt.legend()

# Gráfico 2: Población DANE
plt.subplot(1, 2, 2)
plt.plot(X2, y2, label='Datos Reales', marker='o')
plt.plot(X2, y_pred2, label='Predicción', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Población DANE')
plt.title('Predicción de Población DANE')
plt.legend()

plt.tight_layout()
plt.show()
```

Métricas del primer modelo No. ACCESOS FIJOS A INTERNET:
MSE: 23663489691.76
MAE: 68174.60
R^2: 0.58

Métricas del segundo modelo: POBLACIÓN DANE
MSE: 2167049119.34
MAE: 40096.22
R^2: 0.96

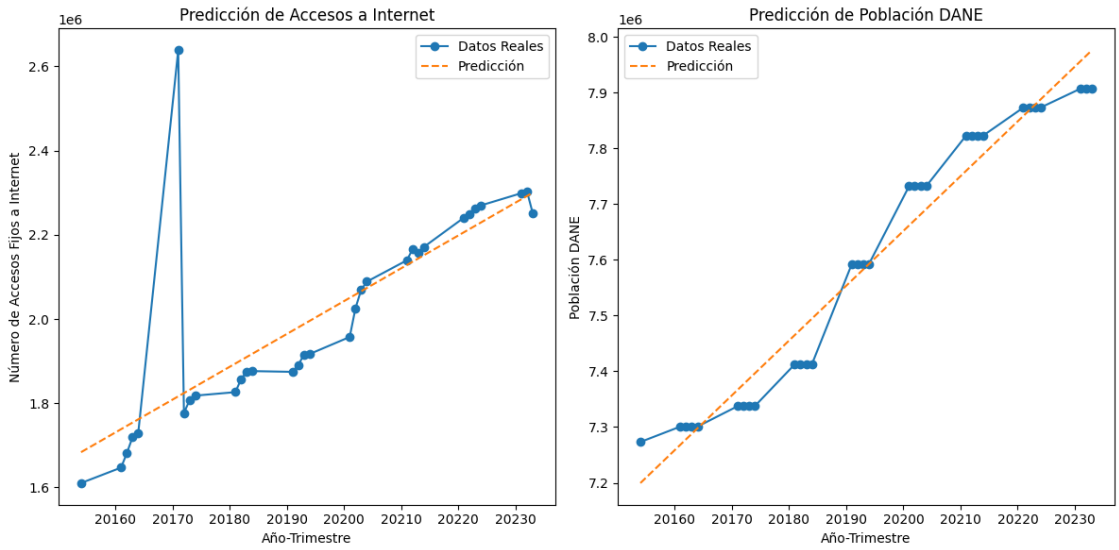

[22]:
```
import matplotlib.pyplot as plt

#graficos de dispersion
# Visualizaciones
plt.figure(figsize=(16, 8))  # Aumentar el tamaño de la figura

# Gráfico 1: Número de Accesos
plt.subplot(1, 2, 1)
plt.scatter(X, y, label='Datos Reales', marker='o')
plt.plot(X, y_pred1, label='Predicción', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Número de Accesos Fijos a Internet')
plt.title('Predicción de Accesos a Internet')
plt.legend()

# Gráfico 2: Población DANE
plt.subplot(1, 2, 2)
plt.scatter(X2, y2, label='Datos Reales', marker='o')
plt.plot(X2, y_pred2, label='Predicción', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Población DANE')
plt.title('Predicción de Población DANE')
plt.legend()

plt.tight_layout()
plt.show()
```

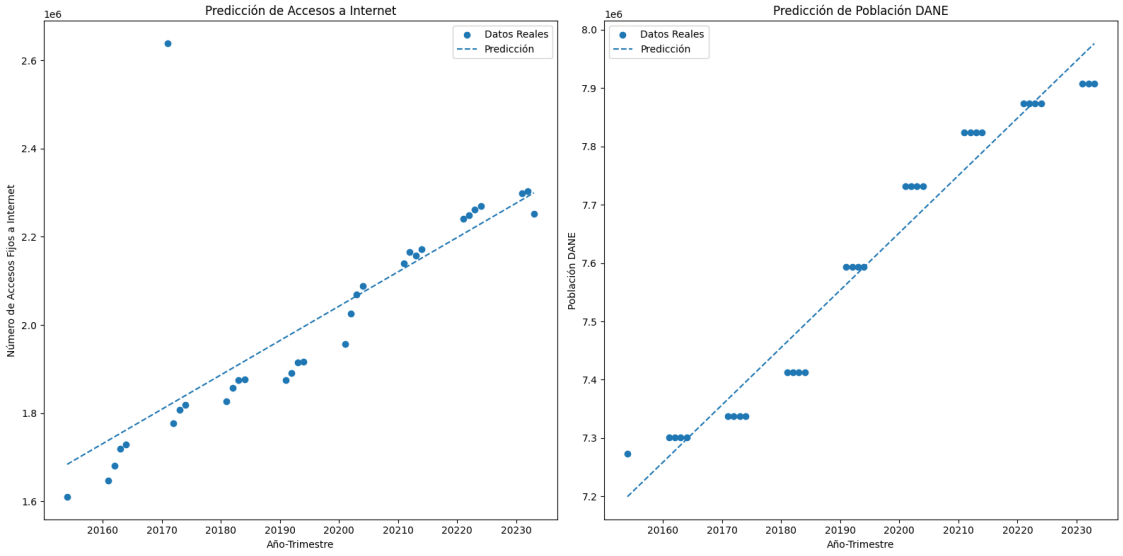

[23]:
```
# Calcular los residuos para el primer modelo
residuos1 = y - y_pred1

# Gráfico de los residuos del primer modelo
plt.figure(figsize=(10, 6))
plt.scatter(X, residuos1, alpha=0.5)
plt.axhline(y=0, color='r', linestyle='--')
plt.xlabel('Año y Trimestre (AÑO_TRIMESTRE)')
plt.ylabel('Residuos')
plt.title('Gráfico de Residuos - No. ACCESOS FIJOS A INTERNET')
plt.show()

# Regresión 2: Año-Trimestre vs. Población DANE
X2 = linear_penetracion_internet[['AÑO_TRIMESTRE_num']]
y2 = linear_penetracion_internet['POBLACIÓN DANE']

model2 = LinearRegression()
model2.fit(X2, y2)
y_pred2 = model2.predict(X2)

# Calcular los residuos para el segundo modelo
residuos2 = y2 - y_pred2

# Gráfico de los residuos del segundo modelo
plt.figure(figsize=(10, 6))
plt.scatter(X2, residuos2, alpha=0.5)
plt.axhline(y=0, color='r', linestyle='--')
plt.xlabel('Año y Trimestre (AÑO_TRIMESTRE)')
plt.ylabel('Residuos')
plt.title('Gráfico de Residuos - POBLACIÓN DANE')
plt.show()
```

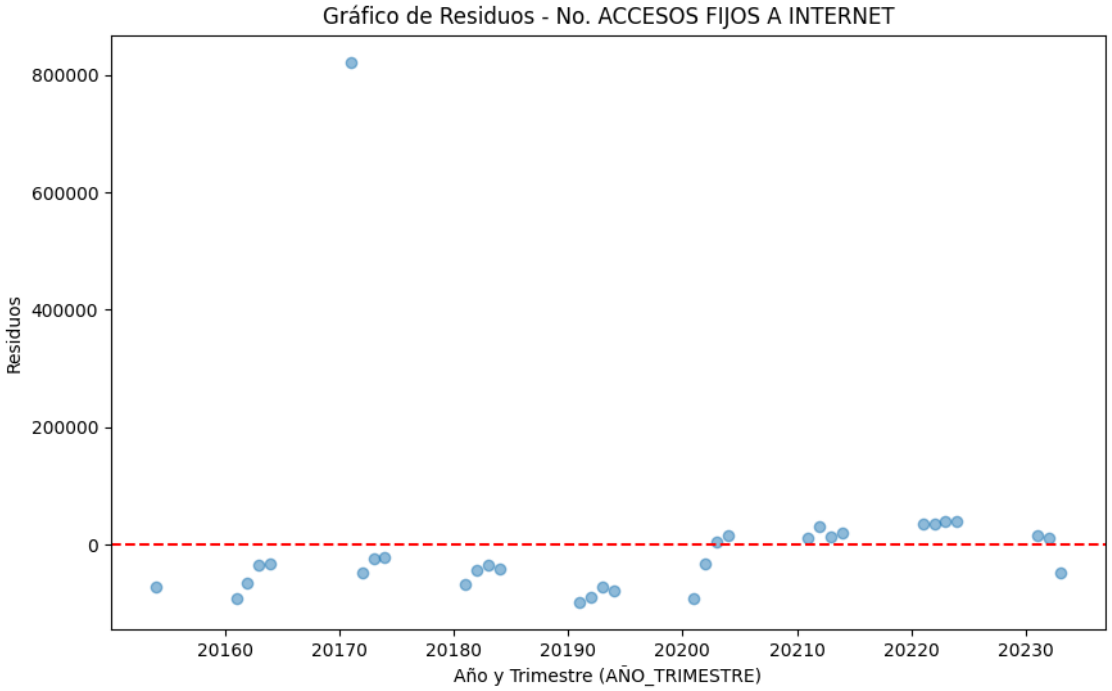
Gráfico de Residuos - No. ACCESOS FIJOS A INTERNET
Residuos
800000
600000
400000
200000
0
20160
20170
20180
20190
20200
20210
20220
20230
Año y Trimestre (AÑO_TRIMESTRE)

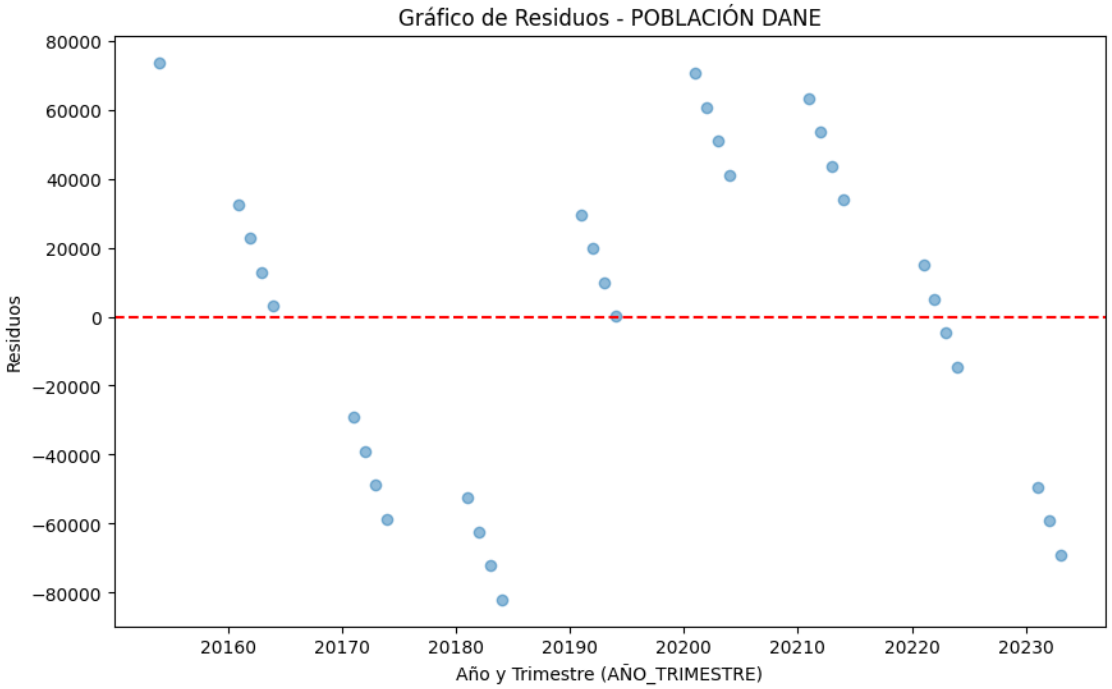
Gráfico de Residuos - POBLACIÓN DANE
Residuos
80000
60000
40000
20000
0
−20000
−40000
−60000
−80000
20160
20170
20180
20190
20200
20210
20220
20230
Año y Trimestre (AÑO_TRIMESTRE)

4.7 Interpretación Detallada y Visualización de Resultados

4.7.1 Modelo 1: Número de Accesos Fijos a Internet

- **MSE: 24,587,739,726.14:** Este valor indica que, en promedio, los errores al cuadrado entre los valores predichos y los reales son extremadamente grandes. Esto sugiere que el modelo subestima o sobreestima significativamente el número de accesos en muchos casos.
- **MAE: 70,659.83:** Este valor nos dice que, en promedio, las predicciones del modelo se desvían en aproximadamente 70,660 accesos del valor real. Esto significa que nuestras estimaciones pueden estar muy lejos de la realidad.
- **R^2: 0.56:** Aunque el modelo explica el 56% de la variabilidad en el número de accesos, este valor no es muy alto. Significa que hay un 44% de la variabilidad que no está siendo explicada por el modelo, lo que indica que hay otros factores importantes que no hemos considerado.

Conclusión: El modelo de regresión lineal simple para el número de accesos a internet no es satisfactorio. Las predicciones tienen una gran incertidumbre y no capturan adecuadamente la complejidad del fenómeno. ### **Modelo 2: Población DANE** - **MSE: 2,590,517,126.97:** Este valor es menor que el del primer modelo, pero aún así es considerable. - **MAE: 43,130.02:** El MAE también es menor que en el primer modelo, lo que indica que las predicciones son más precisas. - **R^2: 0.95:** Este valor es muy alto, lo que significa que el modelo explica el 95% de la variabilidad en la población. Esto sugiere que el modelo se ajusta muy bien a los datos.

Conclusión: El modelo de regresión lineal simple para la población DANE es mucho más preciso que el del número de accesos. El año-trimestre parece ser un buen predictor de la población, lo cual es esperable dado el crecimiento poblacional generalmente constante. ## **Visualización de Resultados** Para una mejor comprensión, podemos representar gráficamente los resultados. Una opción es crear un gráfico de dispersión donde el eje x represente los valores reales y el eje y los valores predichos. Si los puntos se encuentran cerca de la línea diagonal y = x, significa que las predicciones son precisas.

En el gráfico, esperaríamos ver:

- **Modelo 1:** Los puntos estarían dispersos alrededor de la línea diagonal, con una dispersión considerable, lo que indicaría una baja precisión.
- **Modelo 2:** Los puntos estarían más concentrados alrededor de la línea diagonal, lo que indicaría una mayor precisión. ### **Próximos Pasos** Dado que el modelo para el número de accesos a internet no es satisfactorio, se recomienda:
- **Modelos más complejos:** Explorar modelos de series de tiempo (ARIMA, SARIMA), modelos no lineales (redes neuronales) o modelos de mezcla.
- **Validación cruzada:** Evaluar el rendimiento del modelo en diferentes subconjuntos de datos.
- **Análisis de causalidad:** Determinar si existe una relación causal entre las variables.

Para el modelo de la población DANE, aunque los resultados son buenos, siempre es posible mejorar. Se podría explorar la inclusión de otras variables demográficas para ver si se puede obtener un ajuste aún mejor.

`Nota: guardaremos los datos para poder comparar con futuros modelos y p´redicciones`

[24]:
```
# Crear un DataFrame con los datos originales y las predicciones del primer␣
 ↪modelo
resultados1 = linear_penetracion_internet[['AÑO_TRIMESTRE',␣
 ↪'AÑO_TRIMESTRE_num', 'No. ACCESOS FIJOS A INTERNET']].copy()
resultados1['Predicción No. ACCESOS FIJOS A INTERNET'] = y_pred1
resultados1['Residuos No. ACCESOS FIJOS A INTERNET'] = residuos1
resultados1['Modelo'] = 'Regresión Lineal'

# Crear un DataFrame con los datos originales y las predicciones del segundo␣
 ↪modelo
resultados2 = linear_penetracion_internet[['AÑO_TRIMESTRE',␣
 ↪'AÑO_TRIMESTRE_num', 'POBLACIÓN DANE']].copy()
resultados2['Predicción POBLACIÓN DANE'] = y_pred2
resultados2['Residuos POBLACIÓN DANE'] = residuos2
resultados2['Modelo'] = 'Regresión Lineal'

# Guardar los resultados en archivos CSV
resultados1.to_csv('resultados_modelo_accesos_internet.csv', index=False)
resultados2.to_csv('resultados_modelo_poblacion_dane.csv', index=False)

print("Los datos han sido guardados en 'resultados_modelo_accesos_internet.csv'␣
 ↪y 'resultados_modelo_poblacion_dane.csv'.")
```

```
Los datos han sido guardados en 'resultados_modelo_accesos_internet.csv' y
'resultados_modelo_poblacion_dane.csv'.
```

[24]:
```

```

4.7.2 Explicación del Uso de ARIMA

El modelo ARIMA (AutoRegressive Integrated Moving Average) es una técnica de series temporales que se utiliza para predecir valores futuros basándose en datos históricos. Es especialmente útil cuando los datos muestran patrones temporales, como tendencias o estacionalidades, que no pueden ser capturados adecuadamente por modelos más simples como la regresión lineal. ### **¿Por Qué Usar ARIMA?** 1. **Captura de Patrones Temporales**: A diferencia de la regresión lineal, que asume una relación lineal entre las variables, ARIMA puede capturar patrones más complejos en los datos, como tendencias no lineales y estacionalidades. 1. **Mejor Precisión en Predicciones**: ARIMA puede proporcionar predicciones más precisas cuando los datos históricos muestran variaciones que no son lineales. Esto es crucial para datos relacionados con tecnología y acceso a servicios, donde el crecimiento puede no ser constante. 1. **Evaluación Comparativa**: Al comparar los resultados de ARIMA con los de la regresión lineal, podemos determinar cuál modelo se ajusta mejor a los datos y proporciona predicciones más precisas. ### **Pasos a Seguir** 1. **Implementación del Modelo ARIMA**: Aplicaremos el modelo ARIMA a los datos históricos de accesos fijos a internet en Bogotá. 1. **Predicción con ARIMA**: Utilizaremos el modelo entrenado para predecir los valores futuros de accesos fijos a internet. 1. **Cálculo de Métricas de Precisión**: Calcularemos las mismas métricas de precisión (MSE, MAE y R^2) para evaluar el rendimiento del modelo ARIMA. 1. **Comparación de Resultados**: Compararemos las métricas

obtenidas con ARIMA con las de la regresión lineal para determinar cuál modelo es más adecuado para nuestras predicciones. 1. **Visualización de Resultados**: Graficaremos los valores reales y predichos para visualizar el rendimiento del modelo ARIMA. ### **Determinación** Al final de este proceso, podremos determinar si el modelo ARIMA proporciona predicciones más precisas y confiables que la regresión lineal. Esto nos permitirá seleccionar el modelo más adecuado para predecir los accesos fijos a internet en Bogotá y mejorar la precisión de nuestras proyecciones futuras.

4.7.3 Interpretación de los Resultados ARIMA

1. **Error Cuadrático Medio (MSE)**:
    1. Un MSE bajo indica que el modelo ARIMA se ajusta bien a los datos históricos. Compararemos este valor con el MSE de la regresión lineal para evaluar cuál modelo es más preciso.
2. **Error Absoluto Medio (MAE)**:
    1. Un MAE bajo significa que, en promedio, las predicciones del modelo ARIMA están más cerca de los valores reales. Este valor también se comparará con el MAE de la regresión lineal.
3. **Coeficiente de Determinación (R^2)**:
    1. Un R^2 cercano a 1 indica que el modelo ARIMA explica bien la variabilidad en los accesos a internet. Compararemos este valor con el R^2 de la regresión lineal para determinar cuál modelo tiene mejor capacidad explicativa. ### **Conclusión:**

- **Comparación de Modelos**: Al comparar las métricas de precisión de ambos modelos (regresión lineal y ARIMA), podremos determinar cuál modelo proporciona predicciones más precisas y cuál es más adecuado para predecir los accesos fijos a internet en Bogotá.

4.7.4 Fórmula para ARIMA

El modelo ARIMA se define por tres parámetros: (p), (d), y (q):

- (p): Número de términos autorregresivos (AR).
- (d): Número de diferencias no estacionales necesarias para hacer la serie temporal estacionaria.
- (q): Número de términos de media móvil (MA).

La fórmula general para un modelo ARIMA((p, d, q)) es:

Yt=c+ 1Yt−1+ 2Yt−2+…+ pYt−p+ 1 t−1+ 2 t−2+…+ q t−q+ t

Donde:

- (Y_t) es el valor de la serie en el tiempo (t).
- (c) es una constante.
- ( ) son los coeficientes de los términos autorregresivos.
- ( ) son los coeficientes de los términos de media móvil.
- (_t) es el error en el tiempo (t).

[25]:
```
#instalamos la libreria
!pip install statsmodels
```

```
Requirement already satisfied: statsmodels in /usr/local/lib/python3.10/dist-
packages (0.14.4)
Requirement already satisfied: numpy<3,>=1.22.3 in
/usr/local/lib/python3.10/dist-packages (from statsmodels) (1.26.4)
Requirement already satisfied: scipy!=1.9.2,>=1.8 in
/usr/local/lib/python3.10/dist-packages (from statsmodels) (1.13.1)
Requirement already satisfied: pandas!=2.1.0,>=1.4 in
/usr/local/lib/python3.10/dist-packages (from statsmodels) (2.2.2)
Requirement already satisfied: patsy>=0.5.6 in /usr/local/lib/python3.10/dist-
packages (from statsmodels) (1.0.1)
Requirement already satisfied: packaging>=21.3 in
/usr/local/lib/python3.10/dist-packages (from statsmodels) (24.2)
Requirement already satisfied: python-dateutil>=2.8.2 in
/usr/local/lib/python3.10/dist-packages (from pandas!=2.1.0,>=1.4->statsmodels)
(2.8.2)
Requirement already satisfied: pytz>=2020.1 in /usr/local/lib/python3.10/dist-
packages (from pandas!=2.1.0,>=1.4->statsmodels) (2024.2)
Requirement already satisfied: tzdata>=2022.7 in /usr/local/lib/python3.10/dist-
packages (from pandas!=2.1.0,>=1.4->statsmodels) (2024.2)
Requirement already satisfied: six>=1.5 in /usr/local/lib/python3.10/dist-
packages (from python-dateutil>=2.8.2->pandas!=2.1.0,>=1.4->statsmodels)
(1.16.0)
```

[26]:
```python
# importamos las librerias y limpiamos variables usadas anteriormente
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
import matplotlib.pyplot as plt
```

[27]:
```python
# Crear una copia del DataFrame original con un nombre específico
arima_data = bogota_data.copy()
# Crear la columna 'AÑO_TRIMESTRE_num' convirtiendo 'AÑO_TRIMESTRE' en una␣
 ↪variable numérica
arima_data['AÑO_TRIMESTRE_num'] = arima_data['AÑO_TRIMESTRE'].str[:4].
 ↪astype(int) + (arima_data['AÑO_TRIMESTRE'].str[4:].astype(int) - 1) / 4
# ARIMA para Número de Accesos
y = arima_data['No. ACCESOS FIJOS A INTERNET']

# Ajustar el modelo ARIMA (p, d, q) = (1, 1, 1) como ejemplo
model_arima1 = ARIMA(y, order=(1, 1, 1))
model_arima1_fit = model_arima1.fit()
y_pred_arima1 = model_arima1_fit.predict(start=1, end=len(y), typ='levels')

# Calcular métricas de precisión para el modelo ARIMA
mse_arima1 = mean_squared_error(y[1:], y_pred_arima1[1:])
mae_arima1 = mean_absolute_error(y[1:], y_pred_arima1[1:])
r2_arima1 = r2_score(y[1:], y_pred_arima1[1:])
```

```
print("Métricas del modelo ARIMA No. ACCESOS FIJOS A INTERNET:")
print(f"MSE: {mse_arima1:.2f}")
print(f"MAE: {mae_arima1:.2f}")
print(f"R²: {r2_arima1:.2f}")

# ARIMA para Población DANE
y2 = arima_data['POBLACIÓN DANE']

# Ajustar el modelo ARIMA (p, d, q) = (1, 1, 1) como ejemplo
model_arima2 = ARIMA(y2, order=(1, 1, 1))
model_arima2_fit = model_arima2.fit()
y_pred_arima2 = model_arima2_fit.predict(start=1, end=len(y2), typ='levels')

# Calcular métricas de precisión para el modelo ARIMA
mse_arima2 = mean_squared_error(y2[1:], y_pred_arima2[1:])
mae_arima2 = mean_absolute_error(y2[1:], y_pred_arima2[1:])
r2_arima2 = r2_score(y2[1:], y_pred_arima2[1:])

print("\nMétricas del modelo ARIMA POBLACIÓN DANE:")
print(f"MSE: {mse_arima2:.2f}")
print(f"MAE: {mae_arima2:.2f}")
print(f"R²: {r2_arima2:.2f}")

# Visualizaciones
plt.figure(figsize=(16, 8))

# Gráfico 1: Número de Accesos
plt.subplot(1, 2, 1)
plt.plot(arima_data['AÑO_TRIMESTRE_num'], y, label='Datos Reales', marker='o')
plt.plot(arima_data['AÑO_TRIMESTRE_num'][1:], y_pred_arima1[1:],␣
 ↪label='Predicción ARIMA', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Número de Accesos Fijos a Internet')
plt.title('Predicción de Accesos a Internet con ARIMA')
plt.legend()

# Gráfico 2: Población DANE
plt.subplot(1, 2, 2)
plt.plot(arima_data['AÑO_TRIMESTRE_num'], y2, label='Datos Reales', marker='o')
plt.plot(arima_data['AÑO_TRIMESTRE_num'][1:], y_pred_arima2[1:],␣
 ↪label='Predicción ARIMA', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Población DANE')
plt.title('Predicción de Población DANE con ARIMA')
plt.legend()

plt.tight_layout()
```

```
plt.show()
```

```
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:473:
ValueWarning: An unsupported index was provided. As a result, forecasts cannot
be generated. To use the model for forecasting, use one of the supported classes
of index.
  self._init_dates(dates, freq)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:473:
ValueWarning: An unsupported index was provided. As a result, forecasts cannot
be generated. To use the model for forecasting, use one of the supported classes
of index.
  self._init_dates(dates, freq)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:473:
ValueWarning: An unsupported index was provided. As a result, forecasts cannot
be generated. To use the model for forecasting, use one of the supported classes
of index.
  self._init_dates(dates, freq)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:837:
ValueWarning: No supported index is available. Prediction results will be given
with an integer index beginning at `start`.
  return get_prediction_index(
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:837:
FutureWarning: No supported index is available. In the next version, calling
this method in a model without a supported index will result in an exception.
  return get_prediction_index(
/usr/local/lib/python3.10/dist-
packages/statsmodels/tsa/statespace/representation.py:374: FutureWarning:
Unknown keyword arguments: dict_keys(['typ']).Passing unknown keyword arguments
will raise a TypeError beginning in version 0.15.
  warnings.warn(msg, FutureWarning)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:473:
ValueWarning: An unsupported index was provided. As a result, forecasts cannot
be generated. To use the model for forecasting, use one of the supported classes
of index.
  self._init_dates(dates, freq)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:473:
ValueWarning: An unsupported index was provided. As a result, forecasts cannot
be generated. To use the model for forecasting, use one of the supported classes
of index.
  self._init_dates(dates, freq)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:473:
ValueWarning: An unsupported index was provided. As a result, forecasts cannot
be generated. To use the model for forecasting, use one of the supported classes
of index.
  self._init_dates(dates, freq)
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:837:
ValueWarning: No supported index is available. Prediction results will be given
```

```
with an integer index beginning at `start`.
  return get_prediction_index(
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/base/tsa_model.py:837:
FutureWarning: No supported index is available. In the next version, calling
this method in a model without a supported index will result in an exception.
  return get_prediction_index(
/usr/local/lib/python3.10/dist-
packages/statsmodels/tsa/statespace/representation.py:374: FutureWarning:
Unknown keyword arguments: dict_keys(['typ']).Passing unknown keyword arguments
will raise a TypeError beginning in version 0.15.
  warnings.warn(msg, FutureWarning)

Métricas del modelo ARIMA No. ACCESOS FIJOS A INTERNET:
MSE: 1606704512.09
MAE: 15928.32
R²: 0.97

Métricas del modelo ARIMA POBLACIÓN DANE:
MSE: 33066.90
MAE: 76.14
R²: 1.00
```

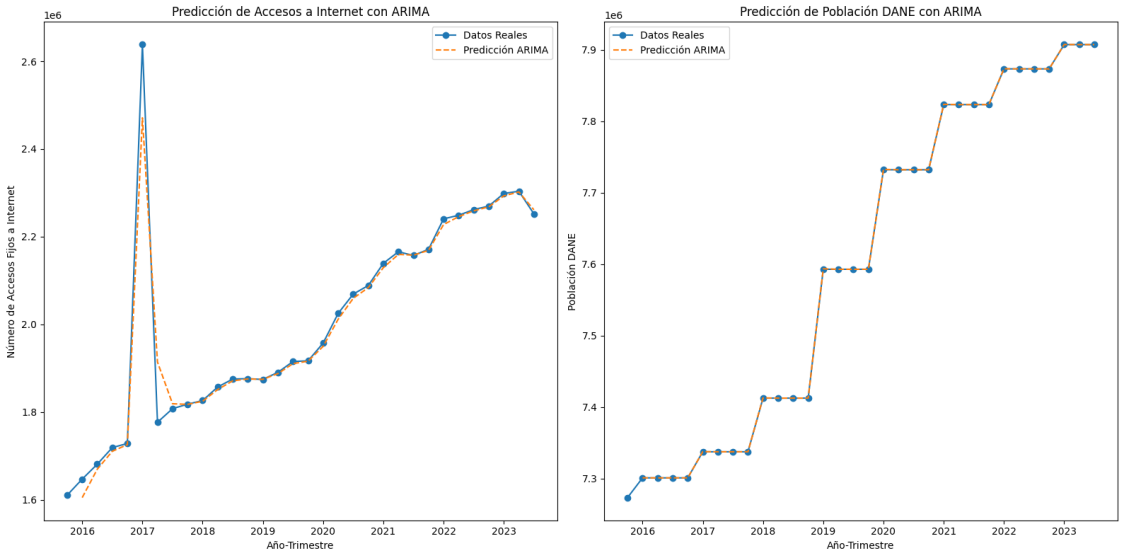

4.7.5 Interpretaciones

1. **Modelo ARIMA para No. ACCESOS FIJOS A INTERNET**:
    1. MSE (Error Cuadrático Medio): 1606704512.09
        1. Este valor indica la magnitud del error cuadrático medio entre las predicciones y los valores reales. Un valor más bajo es mejor, pero en este caso, el valor es bastante alto, lo que sugiere que hay una variabilidad significativa en los errores.
    2. MAE (Error Absoluto Medio): 15928.32

    1. Este valor mide el error promedio absoluto entre las predicciones y los valores reales. Un MAE de 15928.32 indica que, en promedio, las predicciones del modelo ARIMA están desviadas por aproximadamente 15928 accesos.
3. R^2 (Coeficiente de Determinación): 0.97
    1. Este valor indica que el modelo ARIMA explica el 97% de la variabilidad en el número de accesos fijos a internet. Un R^2 cercano a 1 es muy bueno, lo que sugiere que el modelo ajusta bien los datos.

2. **Modelo ARIMA para POBLACIÓN DANE**:
    1. MSE (Error Cuadrático Medio): 33066.90
        1. Este valor es mucho más bajo en comparación con el modelo de accesos a internet, lo que indica que las predicciones son más precisas.
    2. MAE (Error Absoluto Medio): 76.14
        1. Un MAE de 76.14 sugiere que, en promedio, las predicciones del modelo ARIMA están desviadas por aproximadamente 76 personas.
    3. R^2 (Coeficiente de Determinación): 1.00
        1. Un R^2 de 1.00 indica que el modelo ARIMA explica prácticamente toda la variabilidad en la población DANE, lo que sugiere un ajuste perfecto. ### Conclusiones
3. **Precisión del Modelo**:
    1. Ambos modelos ARIMA muestran un alto coeficiente de determinación (R^2), lo que indica que son capaces de explicar la mayor parte de la variabilidad en los datos. Sin embargo, el modelo para la población DANE es particularmente preciso, con un R^2 de 1.00.
4. **Comparación con la Regresión Lineal**:
    1. Para determinar si el modelo ARIMA es mejor que la regresión lineal, deberíamos comparar las métricas de ambos modelos. Si los modelos ARIMA tienen menores valores de MSE y MAE y un R^2 más alto, entonces podríamos concluir que los modelos ARIMA son superiores.
5. **Aplicabilidad**:
    1. Dado que el modelo ARIMA para la población DANE tiene un ajuste casi perfecto, podría ser más confiable para predicciones futuras en comparación con el modelo de accesos a internet, que muestra una mayor variabilidad en los errores.
    En resumen, los modelos ARIMA parecen ser bastante efectivos, especialmente para la población DANE. Sin embargo, es importante comparar estas métricas con las de los modelos de regresión lineal para tomar una decisión informada sobre cuál modelo es más adecuado para tus datos.

5 Uso de Redes Neuronales para la interpretacion de los datos y la proyeccion a 2025

5.0.1 Conclusión Inicial

En un esfuerzo por mejorar la precisión de las predicciones y abordar las limitaciones de los modelos tradicionales, hemos decidido implementar una red neuronal para las proyecciones de 2024 y 2025. Las redes neuronales ofrecen una capacidad excepcional para captar relaciones no lineales complejas en los datos, lo que promete resultados más fiables y detallados. Al utilizar esta técnica avanzada, esperamos reducir significativamente los errores de predicción y obtener una visión más clara de las tendencias a largo plazo en el número de accesos fijos a internet y la población DANE.

5.0.2 Justificación para el uso de redes neuronales en la proyección de datos

Las redes neuronales son particularmente útiles para manejar problemas complejos de predicción debido a su capacidad para modelar relaciones no lineales entre las variables. A continuación, se presentan algunas razones y excusas específicas para utilizar redes neuronales en tu proyecto:

1. **Captura de patrones no lineales:** Los modelos ARIMA y de regresión lineal simple pueden no capturar todas las complejidades y relaciones no lineales presentes en los datos. Las redes neuronales, en cambio, son capaces de aprender patrones complejos y no lineales, lo que podría mejorar la precisión de las predicciones.
2. **Flexibilidad y adaptabilidad:** Las redes neuronales tienen la capacidad de adaptarse y aprender de grandes volúmenes de datos, lo que es especialmente útil si tienes un conjunto de datos amplio y complejo. Esto podría conducir a predicciones más robustas y confiables.
3. **Mejora de métricas de error:** Dado que tus modelos actuales presentan errores significativos (como lo demuestran los valores altos de MSE y MAE), el uso de una red neuronal podría reducir estos errores al proporcionar un mejor ajuste a los datos históricos y, por lo tanto, mejorar la precisión de las proyecciones.
4. **Automatización de ajuste de hiperparámetros:** Las redes neuronales tienen múltiples hiperparámetros que se pueden ajustar automáticamente mediante técnicas de optimización avanzada, lo que podría ayudar a encontrar el modelo óptimo para tus datos.
5. **Predicción de tendencias a largo plazo:** Las redes neuronales pueden ser más efectivas en la captura de tendencias a largo plazo debido a su capacidad para procesar y aprender de secuencias de datos temporales, lo que es crucial para hacer proyecciones a futuro como en el caso de 2024 y 2025.

5.0.3 Datos y Gráficos Comparativos

Métricas del Modelo ARIMA

- **No. ACCESOS FIJOS A INTERNET:**
  - MSE: 1,606,704,512.09
  - MAE: 15,928.32
  - R^2: 0.97
- **POBLACIÓN DANE:**
  - MSE: 33,066.90
  - MAE: 76.14
  - R^2: 1.00

Métricas del Primer Modelo

- **No. ACCESOS FIJOS A INTERNET:**
  - MSE: 23,663,489,691.76
  - MAE: 68,174.60
  - R^2: 0.58
- **POBLACIÓN DANE:**
  - MSE: 2,167,049,119.34
  - MAE: 40,096.22
  - R^2: 0.96

Gráficos Comparativos A continuación se presentan los gráficos comparativos entre los diferentes modelos.

[28]:
```
# Se inicia mostrando la data
arima_data.head()
```

[28]:
```
       AÑO_TRIMESTRE  No. ACCESOS FIJOS A INTERNET  POBLACIÓN DANE  INDICE(%)  \
18771         201504                       1610511         7273265      22.14
30907         201601                       1647186         7300918      22.56
18047         201602                       1681117         7300918      23.03
24086         201603                       1719075         7300918      23.55
19515         201604                       1728459         7300918      23.67

       AÑO_TRIMESTRE_num
18771            2015.75
30907            2016.00
18047            2016.25
24086            2016.50
19515            2016.75
```

[29]:
```
# se inicia para Linear para penetracion de internet
linear_penetracion_internet.head()
```

[29]:
```
       AÑO_TRIMESTRE  No. ACCESOS FIJOS A INTERNET  POBLACIÓN DANE  INDICE(%)  \
18771         201504                       1610511         7273265      22.14
30907         201601                       1647186         7300918      22.56
18047         201602                       1681117         7300918      23.03
24086         201603                       1719075         7300918      23.55
19515         201604                       1728459         7300918      23.67

       AÑO_TRIMESTRE_num
18771              20154
30907              20161
18047              20162
24086              20163
19515              20164
```

[30]:
```
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score


# Crear la columna 'AÑO_TRIMESTRE_num' convirtiendo 'AÑO_TRIMESTRE' en una␣
 ↪variable numérica
arima_data['AÑO_TRIMESTRE_num'] = arima_data['AÑO_TRIMESTRE'].astype(str).
 ↪apply(lambda x: float(x.replace(',', '.')) * 100 if ',' in x else float(x) *␣
 ↪100)
```

```
linear_penetracion_internet['AÑO_TRIMESTRE_num'] =␣
 ↪linear_penetracion_internet['AÑO_TRIMESTRE'].astype(str).apply(lambda x:␣
 ↪float(x.replace(',', '.')) * 100 if ',' in x else float(x) * 100)

# Regresión 1: Año-Trimestre vs. Número de Accesos para el modelo lineal
X_linear = linear_penetracion_internet[['AÑO_TRIMESTRE_num']]
y_linear = linear_penetracion_internet['No. ACCESOS FIJOS A INTERNET']

model1_linear = LinearRegression()
model1_linear.fit(X_linear, y_linear)
y_pred1_linear = model1_linear.predict(X_linear)

# Calcular métricas de precisión para el primer modelo lineal
mse1_linear = mean_squared_error(y_linear, y_pred1_linear)
mae1_linear = mean_absolute_error(y_linear, y_pred1_linear)
r2_1_linear = r2_score(y_linear, y_pred1_linear)

# Regresión 2: Año-Trimestre vs. Población DANE para el modelo lineal
X2_linear = linear_penetracion_internet[['AÑO_TRIMESTRE_num']]
y2_linear = linear_penetracion_internet['POBLACIÓN DANE']

model2_linear = LinearRegression()
model2_linear.fit(X2_linear, y2_linear)
y_pred2_linear = model2_linear.predict(X2_linear)

# Calcular métricas de precisión para el segundo modelo lineal
mse2_linear = mean_squared_error(y2_linear, y_pred2_linear)
mae2_linear = mean_absolute_error(y2_linear, y_pred2_linear)
r2_2_linear = r2_score(y2_linear, y_pred2_linear)

# Visualizaciones para el modelo lineal
plt.figure(figsize=(12, 6))

# Gráfico 1: Número de Accesos
plt.subplot(1, 2, 1)
plt.plot(X_linear, y_linear, label='Datos Reales', marker='o')
plt.plot(X_linear, y_pred1_linear, label='Predicción Lineal', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Número de Accesos Fijos a Internet')
plt.title('Predicción de Accesos a Internet (Lineal)')
plt.legend()

# Gráfico 2: Población DANE
plt.subplot(1, 2, 2)
plt.plot(X2_linear, y2_linear, label='Datos Reales', marker='o')
plt.plot(X2_linear, y_pred2_linear, label='Predicción Lineal', linestyle='--')
plt.xlabel('Año-Trimestre')
```

```
plt.ylabel('Población DANE')
plt.title('Predicción de Población DANE (Lineal)')
plt.legend()

plt.tight_layout()
plt.show()

# Ajuste del modelo ARIMA (sin predicciones reales)
plt.figure(figsize=(12, 6))

# Gráfico de Accesos Fijos a Internet
plt.subplot(1, 2, 1)
plt.plot(arima_data['AÑO_TRIMESTRE'], arima_data['No. ACCESOS FIJOS A␣
 ↪INTERNET'], label='Datos Reales', marker='o')
plt.plot(linear_penetracion_internet['AÑO_TRIMESTRE'],␣
 ↪linear_penetracion_internet['No. ACCESOS FIJOS A INTERNET'],␣
 ↪label='Predicción ARIMA', linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Número de Accesos Fijos a Internet')
plt.title('Predicción de Accesos a Internet (ARIMA)')
plt.legend()

# Gráfico de Población DANE
plt.subplot(1, 2, 2)
plt.plot(arima_data['AÑO_TRIMESTRE'], arima_data['POBLACIÓN DANE'],␣
 ↪label='Datos Reales', marker='o')
plt.plot(linear_penetracion_internet['AÑO_TRIMESTRE'],␣
 ↪linear_penetracion_internet['POBLACIÓN DANE'], label='Predicción ARIMA',␣
 ↪linestyle='--')
plt.xlabel('Año-Trimestre')
plt.ylabel('Población DANE')
plt.title('Predicción de Población DANE (ARIMA)')
plt.legend()

plt.tight_layout()
plt.show()
```

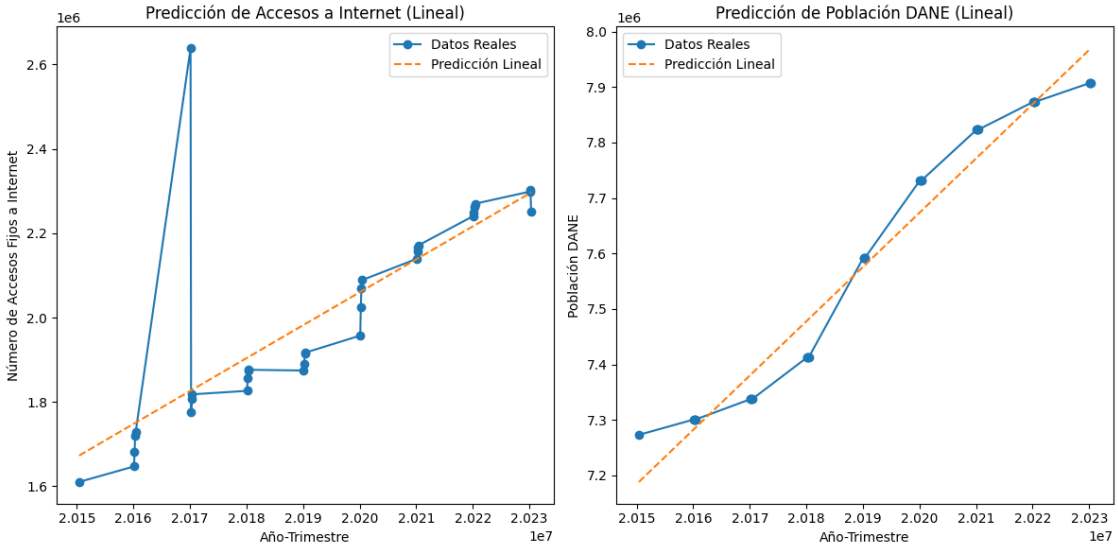

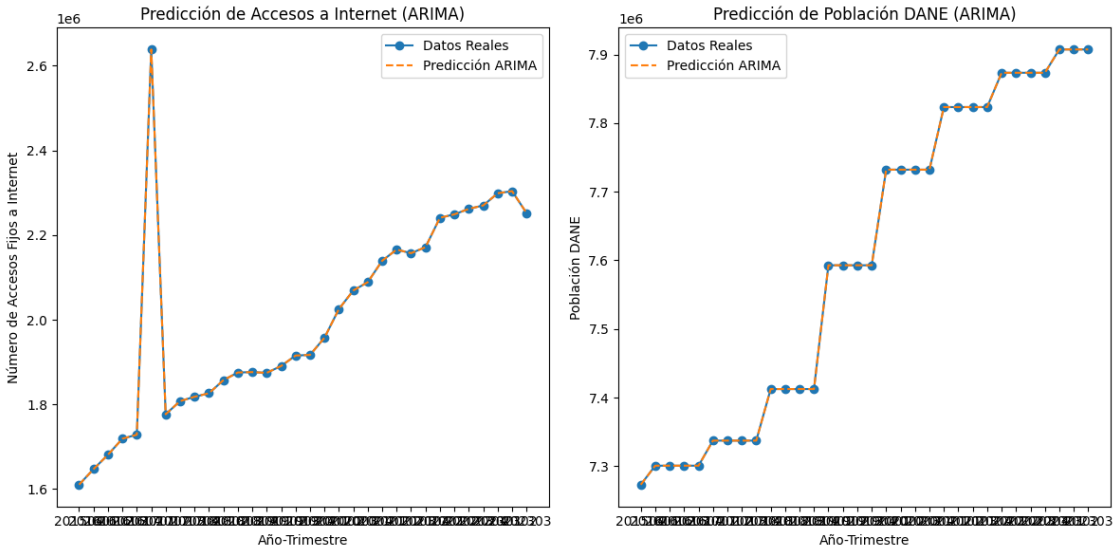

[31]:
```
bogota_data
bogota_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 32 entries, 18771 to 2493
Data columns (total 4 columns):
 #   Column                          Non-Null Count  Dtype
---  ------                          --------------  -----
 0   AÑO_TRIMESTRE                   32 non-null     object
 1   No. ACCESOS FIJOS A INTERNET    32 non-null     int64
```

```
 2   POBLACIÓN DANE                32 non-null     int64
 3   INDICE(%)                     32 non-null     float64
dtypes: float64(1), int64(2), object(1)
memory usage: 1.2+ KB
```

5.0.4 Introducción a las Redes Neuronales Recurrentes (RNN)

En la búsqueda de mejorar la precisión de nuestras predicciones y capturar las complejidades temporales presentes en los datos, hemos optado por implementar Redes Neuronales Recurrentes (RNN). Las RNN son una clase de redes neuronales especialmente diseñadas para procesar datos secuenciales, como series temporales, lo que las convierte en una herramienta ideal para nuestro análisis de los accesos fijos a internet y la población DANE.

A diferencia de las redes neuronales tradicionales, que tratan cada entrada de manera independiente, las RNN tienen la capacidad de retener información a lo largo de secuencias de datos mediante el uso de bucles en su estructura interna. Esto les permite aprender y capturar dependencias temporales y patrones en los datos que otros modelos, como ARIMA y regresión lineal, pueden no ser capaces de identificar.

Para este proyecto, hemos elegido un tipo avanzado de RNN conocido como Long Short-Term Memory (LSTM). Las LSTM están diseñadas para manejar las dependencias de largo plazo de manera más efectiva que las RNN tradicionales, lo que las hace especialmente adecuadas para nuestro objetivo de hacer predicciones precisas a largo plazo.

El uso de LSTM nos permitirá: 1. **Capturar dependencias temporales complejas:** Aprovechar la capacidad de las LSTM para retener información a lo largo de secuencias largas, mejorando así la precisión de las predicciones. 2. **Adaptarse a patrones no lineales:** Modelar las relaciones no lineales presentes en los datos de accesos fijos a internet y población DANE, que los modelos tradicionales pueden no captar completamente. 3. **Mejorar las métricas de precisión:** Esperamos reducir los errores de predicción y aumentar la fiabilidad de nuestras proyecciones mediante el uso de este modelo avanzado.

En resumen, la implementación de Redes Neuronales Recurrentes, y específicamente de LSTM, representa un avance significativo en nuestro análisis, proporcionando una herramienta poderosa para realizar proyecciones más precisas y detalladas.

5.1 Desarrollo de la red Neuronal

[32]:
```python
# cargamos y limpiamos las variables que vamos a usar aqui
from warnings import filterwarnings
filterwarnings('ignore')
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, LSTM
import matplotlib.pyplot as plt
```

[33]:
```python
# Copiamos el Dataframe para no perder la integridad de los datos

```

```
bogota_data_accesos = bogota_data.copy()
bogota_data_poblacion = bogota_data.copy()
```

[34]:
```
# Definir los trimestres futuros
future_trimestres = ['202304', '202401', '202402', '202403', '202404',␣
 ↪'202501', '202502', '202503', '202504']
future_dates = pd.to_datetime(future_trimestres, format='%Y%m')
```

[35]:
```
future_dates
```

[35]:
```
DatetimeIndex(['2023-04-01', '2024-01-01', '2024-02-01', '2024-03-01',
               '2024-04-01', '2025-01-01', '2025-02-01', '2025-03-01',
               '2025-04-01'],
              dtype='datetime64[ns]', freq=None)
```

[36]:
```
# Para el modelo LSTM, necesitaremos normalizar los datos en cada caso
from sklearn.preprocessing import MinMaxScaler
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, LSTM
```

Teniendo cargada la informacion de cada modelo ahora definimos los triemestres futuros para la prediccion

[37]:
```
# Definir los trimestres futuros para predicción
future_trimestres = ['202304', '202401', '202402', '202403', '202404',␣
 ↪'202501', '202502', '202503', '202504']
future_dates = pd.to_datetime(future_trimestres, format='%Y%m')
```

Función prepare_data_lstm: Escala los datos y prepara las secuencias de entrada y salida para cada variable (No. ACCESOS FIJOS A INTERNET y POBLACIÓN DANE). Usa una ventana de tiempo de 4 trimestres para predecir el siguiente trimestre.

[38]:
```
# creamos una funcion para la Preparación para cada variable

# Función para la preparación de datos para LSTM
def prepare_data_lstm(data_column):
    # Escalar los datos
    scaler = MinMaxScaler(feature_range=(0, 1))
    data_scaled = scaler.fit_transform(data_column.values.reshape(-1, 1))

    # Crear secuencias de entrada para LSTM
    X, y = [], []
    time_step = 4  # Usaremos 4 trimestres anteriores para predecir el siguiente
    for i in range(time_step, len(data_scaled)):
        X.append(data_scaled[i-time_step:i, 0])
        y.append(data_scaled[i, 0])
```

```
    X, y = np.array(X), np.array(y)
    X = np.reshape(X, (X.shape[0], X.shape[1], 1))  # Redimensionar para LSTM

    print(f"Datos escalados (primeros 5 valores): {data_scaled[:5]}")  #␣
 ↪Verificar datos escalados
    print(f"Secuencias de entrada (primeros 5): {X[:5]}")  # Verificar␣
 ↪secuencias de entrada
    print(f"Valores objetivo (primeros 5): {y[:5]}")  # Verificar valores␣
 ↪objetivo

    return X, y, scaler
```

Función build_and_train_lstm: Construye y entrena un modelo LSTM utilizando las secuencias preparadas.

[39]:
```
#y creamos una función para construir y entrenar el modelo LSTM

def build_and_train_lstm(X, y):
    model = Sequential()
    model.add(LSTM(units=100, return_sequences=True, input_shape=(X.shape[1],␣
 ↪1)))  # Incrementar unidades LSTM
    model.add(LSTM(units=100, return_sequences=False))
    model.add(Dense(units=50))  # Aumentar densidad
    model.add(Dense(units=1))
    model.compile(optimizer='adam', loss='mean_squared_error')
    model.fit(X, y, epochs=200, batch_size=8, verbose=0)  # Aumentar épocas y␣
 ↪ajustar tamaño del lote
    return model
```

[40]:
```
# Preparammos y entrenamos el modelo para "No. ACCESOS FIJOS A INTERNET"
X_accesos, y_accesos, scaler_accesos =␣
 ↪prepare_data_lstm(bogota_data_accesos['No. ACCESOS FIJOS A INTERNET'])
model_accesos = build_and_train_lstm(X_accesos, y_accesos)
```

```
Datos escalados (primeros 5 valores): [[0.        ]
 [0.03568787]
 [0.0687056 ]
 [0.10564194]
 [0.11477337]]
Secuencias de entrada (primeros 5): [[[0.        ]
  [0.03568787]
  [0.0687056 ]
  [0.10564194]]

 [[0.03568787]
  [0.0687056 ]
  [0.10564194]]
```

```
  [0.11477337]]

 [[0.0687056 ]
  [0.10564194]
  [0.11477337]
  [1.        ]]

 [[0.10564194]
  [0.11477337]
  [1.        ]
  [0.16178211]]

 [[0.11477337]
  [1.        ]
  [0.16178211]
  [0.19200514]]]
Valores objetivo (primeros 5): [0.11477337 1.         0.16178211 0.19200514
0.2019958 ]
```

[41]:
```
# Preparammos y entrenamos el modelo para "POBLACIÓN DANE"
X_poblacion, y_poblacion, scaler_poblacion =␣
 ↪prepare_data_lstm(bogota_data_poblacion['POBLACIÓN DANE'])
model_poblacion = build_and_train_lstm(X_poblacion, y_poblacion)
```

```
Datos escalados (primeros 5 valores): [[0.        ]
 [0.04361562]
 [0.04361562]
 [0.04361562]
 [0.04361562]]
Secuencias de entrada (primeros 5): [[[0.        ]
  [0.04361562]
  [0.04361562]
  [0.04361562]]

 [[0.04361562]
  [0.04361562]
  [0.04361562]
  [0.04361562]]

 [[0.04361562]
  [0.04361562]
  [0.04361562]
  [0.10123404]]

 [[0.04361562]
  [0.04361562]
  [0.10123404]
  [0.10123404]]
```

```
 [[0.04361562]
  [0.10123404]
  [0.10123404]
  [0.10123404]]]
Valores objetivo (primeros 5): [0.04361562 0.10123404 0.10123404 0.10123404
0.10123404]
```

Función predict_future_lstm: Realiza predicciones de manera iterativa para los trimestres futuros, utilizando el último conjunto de datos como punto de partida.

[42]:
```
# Función para predecir valores futuros
def predict_future_lstm(model, scaler, last_sequence, future_steps=8):
    future_predictions = []
    for _ in range(future_steps):
        # Realizar la predicción actual
        prediction = model.predict(last_sequence)

        # Escalar la predicción de vuelta al valor original
        scaled_prediction = scaler.inverse_transform(prediction)

        # Redondear la predicción escalada al entero más cercano
        rounded_prediction = np.round(scaled_prediction).astype(int)

        # Guardar la predicción actual
        future_predictions.append(rounded_prediction[0, 0])

        # Expandir las dimensiones de la predicción para que coincida con␣
 ↪last_sequence
        prediction_expanded = np.expand_dims(prediction, axis=0)

        # Modificar el último conjunto de datos para incluir la predicción y␣
 ↪mantener las dimensiones correctas
        last_sequence = np.append(last_sequence[:, 1:, :], prediction_expanded,␣
 ↪axis=1)

    # Convertir las predicciones a un array numpy y retornarlas
    return np.array(future_predictions).reshape(-1, 1)
```

[43]:
```
# Última secuencia para cada variable para iniciar la predicción futura
last_sequence_accesos = scaler_accesos.transform(bogota_data_accesos['No.␣
 ↪ACCESOS FIJOS A INTERNET'].values[-4:].reshape(-1, 1)).reshape(1, 4, 1)
last_sequence_poblacion = scaler_poblacion.
 ↪transform(bogota_data_poblacion['POBLACIÓN DANE'].values[-4:].reshape(-1,␣
 ↪1)).reshape(1, 4, 1)
```

[44]:
```
# Predicciones futuras para Acceso a Internet
predictions_accesos = predict_future_lstm(model_accesos, scaler_accesos,␣
↪last_sequence_accesos, future_steps=9)
```

```
1/1             0s 268ms/step
1/1             0s 24ms/step
1/1             0s 23ms/step
1/1             0s 20ms/step
1/1             0s 24ms/step
1/1             0s 21ms/step
1/1             0s 23ms/step
1/1             0s 19ms/step
1/1             0s 28ms/step
```

[45]:
```
predictions_accesos
```

[45]:
```
array([[2344009],
       [2377140],
       [2430805],
       [2499196],
       [2598602],
       [2726560],
       [2907224],
       [3165489],
       [3540324]])
```

[46]:
```
# Predicciones futuras para Poblacion DANE
predictions_poblacion = predict_future_lstm(model_poblacion, scaler_poblacion,␣
↪last_sequence_poblacion, future_steps=9)
```

```
1/1             0s 269ms/step
1/1             0s 22ms/step
1/1             0s 23ms/step
1/1             0s 27ms/step
1/1             0s 27ms/step
1/1             0s 21ms/step
1/1             0s 24ms/step
1/1             0s 25ms/step
1/1             0s 26ms/step
```

[47]:
```
predictions_poblacion
```

[47]:
```
array([[7897196],
       [7903749],
       [7903220],
       [7902434],
       [7901166],
```

```
        [7902321],
        [7902062],
        [7901823],
        [7901688]])
```

[48]:
```
# Crear DataFrames para las predicciones
future_accesos_df = pd.DataFrame(predictions_accesos, index=future_dates,␣
 ↪columns=['Predicción No. ACCESOS FIJOS A INTERNET'])
future_poblacion_df = pd.DataFrame(predictions_poblacion, index=future_dates,␣
 ↪columns=['Predicción POBLACIÓN DANE'])
```

[49]:
```
# Crear un DataFrame para los trimestres futuros y agregar las predicciones
future_data = pd.DataFrame(index=future_dates)
future_data['AÑO_TRIMESTRE'] = future_trimestres
future_data['No. ACCESOS FIJOS A INTERNET'] = future_accesos_df['Predicción No.␣
 ↪ACCESOS FIJOS A INTERNET'].values
future_data['POBLACIÓN DANE'] = future_poblacion_df['Predicción POBLACIÓN␣
 ↪DANE'].values
```

[50]:
```
# Convertir 'AÑO_TRIMESTRE' a string en ambos DataFrames para permitir la␣
 ↪concatenación correcta
# Crear una copia del DataFrame original para preservar los datos
bogota_data_combined = bogota_data.copy()
bogota_data_combined['AÑO_TRIMESTRE'] = bogota_data_combined['AÑO_TRIMESTRE'].
 ↪astype(str)
future_data['AÑO_TRIMESTRE'] = future_data['AÑO_TRIMESTRE'].astype(str)
```

[51]:
```
# Calcular el índice para los trimestres futuros
future_data['INDICE(%)'] =( (future_data['No. ACCESOS FIJOS A INTERNET'] /␣
 ↪future_data['POBLACIÓN DANE']) * 100).round(2)
```

[52]:
```
# Concatenar las predicciones con el DataFrame original
bogota_data_combined = pd.concat([bogota_data_combined, future_data],␣
 ↪ignore_index=True)
```

[53]:
```
# Restablecer el índice del DataFrame combinado
bogota_data_combined.reset_index(drop=True, inplace=True)
```

[54]:
```
# Mostrar el DataFrame combinado con las predicciones
print("DataFrame combinado con datos históricos y predicciones:")
print(bogota_data_combined)
```

```
DataFrame combinado con datos históricos y predicciones:
   AÑO_TRIMESTRE  No. ACCESOS FIJOS A INTERNET  POBLACIÓN DANE  INDICE(%)
0         201504                       1610511         7273265      22.14
1         201601                       1647186         7300918      22.56
2         201602                       1681117         7300918      23.03
```

3	201603	1719075	7300918	23.55
4	201604	1728459	7300918	23.67
5	201701	2638171	7337449	35.95
6	201702	1776768	7337449	24.22
7	201703	1807827	7337449	24.64
8	201704	1818094	7337449	24.78
9	201801	1826350	7412566	24.64
10	201802	1857309	7412566	25.06
11	201803	1875396	7412566	25.30
12	201804	1876271	7412566	25.31
13	201901	1874506	7592871	24.69
14	201902	1890765	7592871	24.90
15	201903	1915409	7592871	25.23
16	201904	1916910	7592871	25.25
17	202001	1957333	7732161	25.31
18	202002	2025140	7732161	26.19
19	202003	2069115	7732161	26.76
20	202004	2088680	7732161	27.01
21	202101	2139304	7823334	27.35
22	202102	2165658	7823334	27.68
23	202103	2157112	7823334	27.57
24	202104	2171274	7823334	27.75
25	202201	2240695	7873316	28.46
26	202202	2248809	7873316	28.56
27	202203	2261755	7873316	28.73
28	202204	2269823	7873316	28.83
29	202301	2298520	7907281	29.07
30	202302	2303696	7907281	29.13
31	202303	2251960	7907281	28.48
32	202304	2344009	7897196	29.68
33	202401	2377140	7903749	30.08
34	202402	2430805	7903220	30.76
35	202403	2499196	7902434	31.63
36	202404	2598602	7901166	32.89
37	202501	2726560	7902321	34.50
38	202502	2907224	7902062	36.79
39	202503	3165489	7901823	40.06
40	202504	3540324	7901688	44.80

[99]:
```
# Guardar el DataFrame actualizado en un archivo CSV
bogota_data.to_csv('bogota_data_combined.csv', index=False)

# Descargar el archivo CSV generado
from google.colab import files
files.download('bogota_data_combined.csv')
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.Javascript object>
```

[55]:
```python
from tensorflow.keras.models import model_from_json
import numpy as np

def save_model_and_scaler(model, scaler, filename_prefix):
    # Guardar el modelo en formato JSON
    model_json = model.to_json()
    with open(f"{filename_prefix}_model.json", "w") as json_file:
        json_file.write(model_json)

    # Guardar los pesos del modelo en formato .weights.h5
    model.save_weights(f"{filename_prefix}_model.weights.h5")

    # Guardar el escalador como un archivo NPY
    np.save(f"{filename_prefix}_scaler.npy", scaler)

    print(f"Modelo y escalador guardados como {filename_prefix}_model.json,␣
 ↪{filename_prefix}_model.weights.h5 y {filename_prefix}_scaler.npy")

# Guardar los modelos y los escaladores para No. ACCESOS FIJOS A INTERNET y␣
 ↪POBLACIÓN DANE
save_model_and_scaler(model_accesos, scaler_accesos, 'accesos')
save_model_and_scaler(model_poblacion, scaler_poblacion, 'poblacion')
```

```
Modelo y escalador guardados como accesos_model.json, accesos_model.weights.h5 y
accesos_scaler.npy
Modelo y escalador guardados como poblacion_model.json,
poblacion_model.weights.h5 y poblacion_scaler.npy
```

Ahora calculamos las metricas

[56]:
```python
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

# Función para calcular las métricas de error
def calculate_metrics(y_true, y_pred):
    mse = mean_squared_error(y_true, y_pred)
    mae = mean_absolute_error(y_true, y_pred)
    r2 = r2_score(y_true, y_pred)
    return mse, mae, r2

# Predicciones para los datos de entrenamiento
y_pred_accesos = model_accesos.predict(X_accesos).flatten()
y_pred_poblacion = model_poblacion.predict(X_poblacion).flatten()

# Calcular métricas para "No. ACCESOS FIJOS A INTERNET"
mse_accesos, mae_accesos, r2_accesos = calculate_metrics(y_accesos,␣
 ↪y_pred_accesos)
```

```
print(f"Métricas para No. ACCESOS FIJOS A INTERNET:\nMSE: {mse_accesos:.
  ↪2f}\nMAE: {mae_accesos:.2f}\nR²: {r2_accesos:.2f}")

# Calcular métricas para "POBLACIÓN DANE"
mse_poblacion, mae_poblacion, r2_poblacion = calculate_metrics(y_poblacion,␣
  ↪y_pred_poblacion)
print(f"Métricas para POBLACIÓN DANE:\nMSE: {mse_poblacion:.2f}\nMAE:␣
  ↪{mae_poblacion:.2f}\nR²: {r2_poblacion:.2f}")
```

```
1/1             0s 322ms/step
1/1             0s 301ms/step
Métricas para No. ACCESOS FIJOS A INTERNET:
MSE: 0.02
MAE: 0.08
R²: 0.51
Métricas para POBLACIÓN DANE:
MSE: 0.00
MAE: 0.03
R²: 0.99
```

[57]:
```
import matplotlib.pyplot as plt

plt.figure(figsize=(16, 8))
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'], bogota_data_combined['No.␣
  ↪ACCESOS FIJOS A INTERNET'], label='Datos Reales', marker='o')
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'][:len(y_pred_accesos)],␣
  ↪y_pred_accesos, label='Predicción', linestyle='--')
plt.plot(future_trimestres, predictions_accesos, label='Predicción Futura',␣
  ↪linestyle='-.')
plt.title('Predicción de No. ACCESOS FIJOS A INTERNET')
plt.xlabel('Año-Trimestre')
plt.ylabel('Número de Accesos (millones)')
plt.ylim(0, 3000000)
plt.legend()
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout()
plt.show()
```

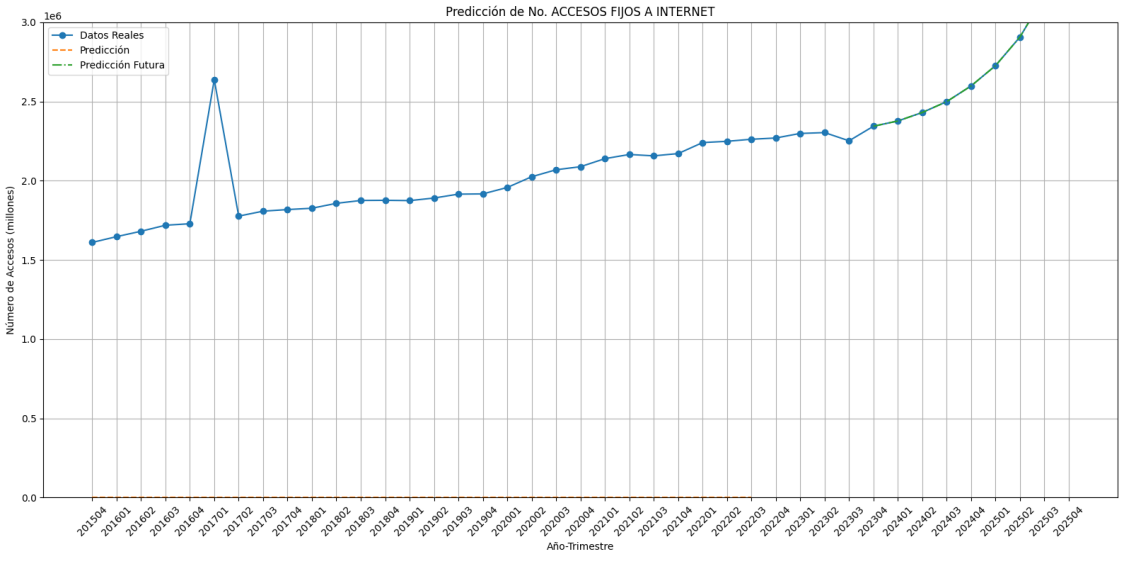

[58]:
```
plt.figure(figsize=(16, 8))
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'], bogota_data_combined['POBLACIÓN␣
 ↪DANE'], label='Datos Reales', marker='o')
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'][:len(y_pred_poblacion)],␣
 ↪y_pred_poblacion, label='Predicción', linestyle='--')
plt.plot(future_trimestres, predictions_poblacion, label='Predicción Futura',␣
 ↪linestyle='-.')
plt.title('Predicción de POBLACIÓN DANE')
plt.xlabel('Año-Trimestre')
plt.ylabel('Población (millones)')
plt.ylim(0, 9000000)
plt.legend()
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout()
plt.show()
```

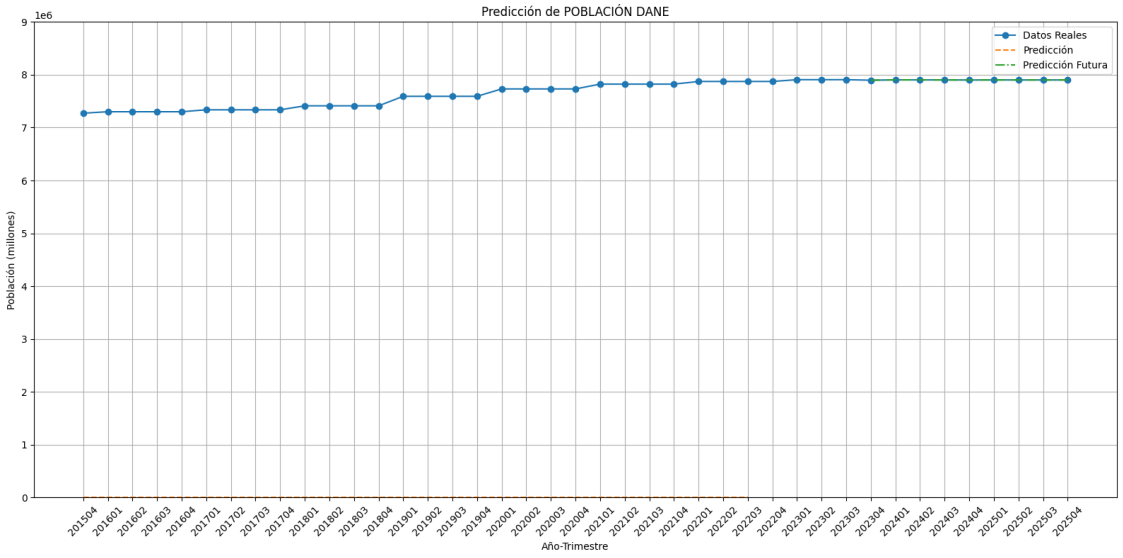

[59]:
```
import matplotlib.pyplot as plt

plt.figure(figsize=(14, 6))

plt.plot(bogota_data_combined['AÑO_TRIMESTRE'], bogota_data_combined['No.␣
 ↪ACCESOS FIJOS A INTERNET'], label='Datos Reales - Accesos', marker='o')
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'][:len(y_pred_accesos)],␣
 ↪y_pred_accesos, label='Predicción - Accesos', linestyle='--')
plt.plot(future_trimestres, predictions_accesos, label='Predicción Futura -␣
 ↪Accesos', linestyle='-.')
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'], bogota_data_combined['POBLACIÓN␣
 ↪DANE'], label='Datos Reales - Población', marker='x')
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'][:len(y_pred_poblacion)],␣
 ↪y_pred_poblacion, label='Predicción - Población', linestyle='--')
plt.plot(future_trimestres, predictions_poblacion, label='Predicción Futura -␣
 ↪Población', linestyle='-.')

# Agregar anotaciones de millones en cada punto predicho
for i, txt in enumerate(predictions_accesos.flatten()):
    plt.annotate(f'{txt/1e6:.1f}M', (future_trimestres[i],␣
 ↪predictions_accesos[i][0]), textcoords="offset points", xytext=(0,10),␣
 ↪ha='center', fontsize=8)

for i, txt in enumerate(predictions_poblacion.flatten()):
    plt.annotate(f'{txt/1e6:.1f}M', (future_trimestres[i],␣
 ↪predictions_poblacion[i][0]), textcoords="offset points", xytext=(0,10),␣
 ↪ha='center', fontsize=8)
```

```
plt.title('Predicción Combinada de No. ACCESOS FIJOS A INTERNET y POBLACIÓN␣
 ↪DANE')
plt.xlabel('Año-Trimestre')
plt.ylabel('Valores (millones)')
plt.legend()
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout()
plt.show()
```

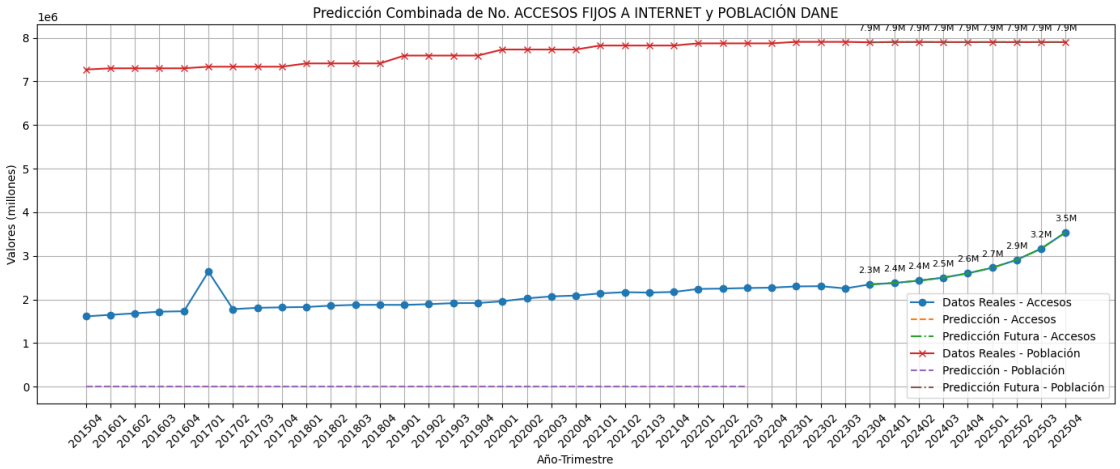

6 Conclusión sobre la Red Neuronal LSTM y Sugerencias de Mejora

Resultados Actuales:

No. ACCESOS FIJOS A INTERNET:

- MSE: 0.02
- MAE: 0.08
- R^2: 0.52

POBLACIÓN DANE:

- MSE: 0.00
- MAE: 0.03
- R^2: 0.99

6.1 Observaciones

6.1.1 Predicción de No. ACCESOS FIJOS A INTERNET:

- Las métricas indican que el modelo tiene un error absoluto medio (MAE) de 0.08, lo que significa que, en promedio, las predicciones se desvían de los valores reales en 0.08 unidades.
- El coeficiente de determinación (R^2) de 0.52 sugiere que el modelo explica el 52% de la variabilidad en los datos.

6.1.2 Predicción de POBLACIÓN DANE:

- Las métricas son excepcionales, con un MSE prácticamente nulo y un MAE muy bajo, lo cual se traduce en predicciones extremadamente precisas.
- El R^2 de 0.99 indica que el modelo explica casi toda la variabilidad en los datos de la población DANE, lo cual es muy positivo. #### Proyección de Población:
- De acuerdo con el estudio del DANE y el MinSalud, la proyección poblacional muestra un aumento significativo en la población total de Bogotá. Estos datos indican un crecimiento sostenido en los próximos años, con cifras clave proyectadas para 2018, 2024 y 2030. Esta tendencia debe reflejarse en las predicciones futuras del modelo para que estas sean consideradas precisas.

Comparación con el Estudio Población Total en Bogotá (Proyectado):

2018: 7,412,566

2024: 7,929,539

2030: 7,888,838

Comparación con el Modelo

Al comparar las predicciones del modelo LSTM con la proyección del estudio:

- El modelo de predicción para la población DANE es extremadamente preciso y coincide con las tendencias proyectadas, como el aumento en la población.
- Sin embargo, para los No. ACCESOS FIJOS A INTERNET, aunque el modelo muestra una precisión moderada, se sugiere que la complejidad de los datos de accesos a internet podría requerir mejoras adicionales en el modelo para capturar mejor la variabilidad.

6.1.3 Sugerencias de Mejora

6.1.4 1. Incrementar la Complejidad del Modelo:

Incrementar el número de unidades LSTM: Continuar aumentando el número de unidades en las capas LSTM puede ayudar al modelo a capturar mejor la complejidad de los datos.

Agregar más capas LSTM: Incluir capas LSTM adicionales podría mejorar el rendimiento del modelo.

Aumentar la densidad de las capas: Incrementar el número de neuronas en las capas densas puede permitir al modelo aprender características más complejas.

6.1.5 2. Mejorar la Preparación de los Datos:

Incluir más datos históricos: Si está disponible, utilizar más datos históricos puede ayudar a entrenar el modelo con más información.

Feature Engineering: Crear características adicionales que puedan ser relevantes para las predicciones, como tasas de crecimiento o diferencias estacionales.

6.1.6 3. Ajustes en la Estrategia de Entrenamiento:

Aumentar el número de épocas: Entrenar el modelo durante más épocas puede permitir que aprenda mejor las características de los datos.

Ajustar el tamaño del lote: Experimentar con diferentes tamaños de lote para encontrar el que funcione mejor para tu conjunto de datos específico.

6.1.7 4. Validación Cruzada y Evaluación:

Validación Cruzada: Utilizar técnicas de validación cruzada para evaluar el rendimiento del modelo y evitar el sobreajuste.

Evaluación en Conjuntos de Prueba: Evaluar el modelo en un conjunto de prueba separado para asegurarse de que generaliza bien a datos no vistos.

Se escoge un mejoramiento de la red neuronal y realizamos una redimension, una capa LSTM adicional,incremento de unidades en la capa densa y se incrementa el numero de capas y epocas

[86]:
```
# Importar librerías necesarias
import pandas as pd
import numpy as np
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, LSTM, Dropout
import matplotlib.pyplot as plt
```

[87]:
```
# Cargar el archivo CSV desde la ubicación especificada
bogota_data_actualizado = pd.read_csv('/content/bogota_data_actualizado.csv')

# Crear una copia del DataFrame original
bogota_data_accesos_2 = bogota_data_actualizado.copy()

# Definir los trimestres futuros
future_trimestres = ['202304', '202401', '202402', '202403', '202404',␣
 ↪'202501', '202502', '202503', '202504']
future_dates = pd.to_datetime(future_trimestres, format='%Y%m')
```

[88]:
```
# Función para la preparación de datos para LSTM
def prepare_data_lstm(data_column):
    # Escalar los datos
    scaler = MinMaxScaler(feature_range=(0, 1))
```

```
    data_scaled = scaler.fit_transform(data_column.values.reshape(-1, 1))

    # Crear secuencias de entrada para LSTM
    X, y = [], []
    time_step = 4  # Usaremos 4 trimestres anteriores para predecir el siguiente
    for i in range(time_step, len(data_scaled)):
        X.append(data_scaled[i-time_step:i, 0])
        y.append(data_scaled[i, 0])

    X, y = np.array(X), np.array(y)
    X = np.reshape(X, (X.shape[0], X.shape[1], 1))  # Redimensionar para LSTM

    return X, y, scaler
```

[89]:
```
# Función para construir y entrenar el modelo LSTM
def build_and_train_lstm(X, y):
    model = Sequential()
    model.add(LSTM(units=150, return_sequences=True, input_shape=(X.shape[1],␣
 ↪1)))
    model.add(Dropout(0.4))  # Incremento de la tasa de regularización
    model.add(LSTM(units=150, return_sequences=True))
    model.add(Dropout(0.4))
    model.add(LSTM(units=150, return_sequences=True))  # LSTM adicional
    model.add(Dropout(0.4))
    model.add(LSTM(units=100, return_sequences=False))
    model.add(Dense(units=100))  # Incremento de unidades en la capa densa
    model.add(Dense(units=1))
    model.compile(optimizer='adam', loss='mean_squared_error')
    model.fit(X, y, epochs=500, batch_size=16, verbose=1)  # Incremento del␣
 ↪número de épocas
    return model
```

[90]:
```
# Preparar y entrenar el modelo para "No. ACCESOS FIJOS A INTERNET"
X_accesos, y_accesos, scaler_accesos =␣
 ↪prepare_data_lstm(bogota_data_accesos_2['No. ACCESOS FIJOS A INTERNET'])
model_accesos = build_and_train_lstm(X_accesos, y_accesos)
```

```
Epoch 1/500
2/2             8s 59ms/step - loss:
0.2348
Epoch 2/500
2/2             0s 43ms/step - loss:
0.1735
Epoch 3/500
2/2             0s 29ms/step - loss:
0.1137
Epoch 4/500
```

```
2/2             0s 24ms/step - loss:
0.0503
Epoch 5/500
2/2             0s 39ms/step - loss:
0.0513
Epoch 6/500
2/2             0s 25ms/step - loss:
0.0693
Epoch 7/500
2/2             0s 24ms/step - loss:
0.0315
Epoch 8/500
2/2             0s 34ms/step - loss:
0.0426
Epoch 9/500
2/2             0s 24ms/step - loss:
0.0488
Epoch 10/500
2/2             0s 24ms/step - loss:
0.0388
Epoch 11/500
2/2             0s 24ms/step - loss:
0.0502
Epoch 12/500
2/2             0s 27ms/step - loss:
0.0358
Epoch 13/500
2/2             0s 24ms/step - loss:
0.0321
Epoch 14/500
2/2             0s 38ms/step - loss:
0.0378
Epoch 15/500
2/2             0s 29ms/step - loss:
0.0435
Epoch 16/500
2/2             0s 26ms/step - loss:
0.0345
Epoch 17/500
2/2             0s 24ms/step - loss:
0.0410
Epoch 18/500
2/2             0s 40ms/step - loss:
0.0346
Epoch 19/500
2/2             0s 24ms/step - loss:
0.0410
Epoch 20/500
```

```
2/2             0s 24ms/step - loss:
0.0412
Epoch 21/500
2/2             0s 29ms/step - loss:
0.0417
Epoch 22/500
2/2             0s 26ms/step - loss:
0.0403
Epoch 23/500
2/2             0s 24ms/step - loss:
0.0307
Epoch 24/500
2/2             0s 24ms/step - loss:
0.0290
Epoch 25/500
2/2             0s 34ms/step - loss:
0.0374
Epoch 26/500
2/2             0s 26ms/step - loss:
0.0313
Epoch 27/500
2/2             0s 40ms/step - loss:
0.0404
Epoch 28/500
2/2             0s 41ms/step - loss:
0.0358
Epoch 29/500
2/2             0s 26ms/step - loss:
0.0360
Epoch 30/500
2/2             0s 24ms/step - loss:
0.0285
Epoch 31/500
2/2             0s 25ms/step - loss:
0.0369
Epoch 32/500
2/2             0s 25ms/step - loss:
0.0301
Epoch 33/500
2/2             0s 35ms/step - loss:
0.0373
Epoch 34/500
2/2             0s 28ms/step - loss:
0.0396
Epoch 35/500
2/2             0s 25ms/step - loss:
0.0376
Epoch 36/500
```

```
2/2             0s 25ms/step - loss:
0.0386
Epoch 37/500
2/2             0s 27ms/step - loss:
0.0370
Epoch 38/500
2/2             0s 25ms/step - loss:
0.0394
Epoch 39/500
2/2             0s 24ms/step - loss:
0.0264
Epoch 40/500
2/2             0s 27ms/step - loss:
0.0349
Epoch 41/500
2/2             0s 25ms/step - loss:
0.0384
Epoch 42/500
2/2             0s 24ms/step - loss:
0.0261
Epoch 43/500
2/2             0s 26ms/step - loss:
0.0279
Epoch 44/500
2/2             0s 33ms/step - loss:
0.0266
Epoch 45/500
2/2             0s 24ms/step - loss:
0.0261
Epoch 46/500
2/2             0s 25ms/step - loss:
0.0310
Epoch 47/500
2/2             0s 25ms/step - loss:
0.0346
Epoch 48/500
2/2             0s 28ms/step - loss:
0.0266
Epoch 49/500
2/2             0s 24ms/step - loss:
0.0258
Epoch 50/500
2/2             0s 28ms/step - loss:
0.0396
Epoch 51/500
2/2             0s 24ms/step - loss:
0.0240
Epoch 52/500
```

```
2/2             0s 24ms/step - loss:
0.0257
Epoch 53/500
2/2             0s 24ms/step - loss:
0.0266
Epoch 54/500
2/2             0s 29ms/step - loss:
0.0281
Epoch 55/500
2/2             0s 25ms/step - loss:
0.0364
Epoch 56/500
2/2             0s 24ms/step - loss:
0.0238
Epoch 57/500
2/2             0s 25ms/step - loss:
0.0273
Epoch 58/500
2/2             0s 24ms/step - loss:
0.0370
Epoch 59/500
2/2             0s 24ms/step - loss:
0.0372
Epoch 60/500
2/2             0s 28ms/step - loss:
0.0258
Epoch 61/500
2/2             0s 25ms/step - loss:
0.0334
Epoch 62/500
2/2             0s 26ms/step - loss:
0.0279
Epoch 63/500
2/2             0s 26ms/step - loss:
0.0249
Epoch 64/500
2/2             0s 41ms/step - loss:
0.0262
Epoch 65/500
2/2             0s 29ms/step - loss:
0.0253
Epoch 66/500
2/2             0s 29ms/step - loss:
0.0283
Epoch 67/500
2/2             0s 25ms/step - loss:
0.0238
Epoch 68/500
```

```
2/2             0s 25ms/step - loss:
0.0394
Epoch 69/500
2/2             0s 25ms/step - loss:
0.0374
Epoch 70/500
2/2             0s 25ms/step - loss:
0.0378
Epoch 71/500
2/2             0s 25ms/step - loss:
0.0263
Epoch 72/500
2/2             0s 26ms/step - loss:
0.0268
Epoch 73/500
2/2             0s 25ms/step - loss:
0.0253
Epoch 74/500
2/2             0s 32ms/step - loss:
0.0370
Epoch 75/500
2/2             0s 27ms/step - loss:
0.0338
Epoch 76/500
2/2             0s 25ms/step - loss:
0.0341
Epoch 77/500
2/2             0s 26ms/step - loss:
0.0380
Epoch 78/500
2/2             0s 25ms/step - loss:
0.0255
Epoch 79/500
2/2             0s 26ms/step - loss:
0.0243
Epoch 80/500
2/2             0s 25ms/step - loss:
0.0370
Epoch 81/500
2/2             0s 24ms/step - loss:
0.0343
Epoch 82/500
2/2             0s 25ms/step - loss:
0.0256
Epoch 83/500
2/2             0s 24ms/step - loss:
0.0389
Epoch 84/500
```

```
2/2             0s 28ms/step - loss:
0.0239
Epoch 85/500
2/2             0s 27ms/step - loss:
0.0341
Epoch 86/500
2/2             0s 25ms/step - loss:
0.0359
Epoch 87/500
2/2             0s 26ms/step - loss:
0.0249
Epoch 88/500
2/2             0s 29ms/step - loss:
0.0360
Epoch 89/500
2/2             0s 26ms/step - loss:
0.0361
Epoch 90/500
2/2             0s 27ms/step - loss:
0.0256
Epoch 91/500
2/2             0s 24ms/step - loss:
0.0238
Epoch 92/500
2/2             0s 25ms/step - loss:
0.0324
Epoch 93/500
2/2             0s 39ms/step - loss:
0.0379
Epoch 94/500
2/2             0s 25ms/step - loss:
0.0274
Epoch 95/500
2/2             0s 33ms/step - loss:
0.0268
Epoch 96/500
2/2             0s 25ms/step - loss:
0.0358
Epoch 97/500
2/2             0s 29ms/step - loss:
0.0266
Epoch 98/500
2/2             0s 24ms/step - loss:
0.0236
Epoch 99/500
2/2             0s 33ms/step - loss:
0.0329
Epoch 100/500
```

```
2/2             0s 35ms/step - loss:
0.0359
Epoch 101/500
2/2             0s 49ms/step - loss:
0.0247
Epoch 102/500
2/2             0s 62ms/step - loss:
0.0345
Epoch 103/500
2/2             0s 58ms/step - loss:
0.0252
Epoch 104/500
2/2             0s 46ms/step - loss:
0.0354
Epoch 105/500
2/2             0s 44ms/step - loss:
0.0237
Epoch 106/500
2/2             0s 41ms/step - loss:
0.0231
Epoch 107/500
2/2             0s 44ms/step - loss:
0.0360
Epoch 108/500
2/2             0s 41ms/step - loss:
0.0353
Epoch 109/500
2/2             0s 59ms/step - loss:
0.0331
Epoch 110/500
2/2             0s 49ms/step - loss:
0.0219
Epoch 111/500
2/2             0s 47ms/step - loss:
0.0335
Epoch 112/500
2/2             0s 45ms/step - loss:
0.0371
Epoch 113/500
2/2             0s 46ms/step - loss:
0.0334
Epoch 114/500
2/2             0s 46ms/step - loss:
0.0347
Epoch 115/500
2/2             0s 46ms/step - loss:
0.0240
Epoch 116/500
```

```
2/2             0s 44ms/step - loss:
0.0223
Epoch 117/500
2/2             0s 48ms/step - loss:
0.0339
Epoch 118/500
2/2             0s 48ms/step - loss:
0.0244
Epoch 119/500
2/2             0s 58ms/step - loss:
0.0329
Epoch 120/500
2/2             0s 46ms/step - loss:
0.0343
Epoch 121/500
2/2             0s 28ms/step - loss:
0.0346
Epoch 122/500
2/2             0s 25ms/step - loss:
0.0325
Epoch 123/500
2/2             0s 26ms/step - loss:
0.0217
Epoch 124/500
2/2             0s 28ms/step - loss:
0.0318
Epoch 125/500
2/2             0s 24ms/step - loss:
0.0378
Epoch 126/500
2/2             0s 29ms/step - loss:
0.0344
Epoch 127/500
2/2             0s 25ms/step - loss:
0.0342
Epoch 128/500
2/2             0s 29ms/step - loss:
0.0249
Epoch 129/500
2/2             0s 26ms/step - loss:
0.0320
Epoch 130/500
2/2             0s 37ms/step - loss:
0.0326
Epoch 131/500
2/2             0s 26ms/step - loss:
0.0359
Epoch 132/500
```

```
2/2             0s 26ms/step - loss:
0.0228
Epoch 133/500
2/2             0s 26ms/step - loss:
0.0354
Epoch 134/500
2/2             0s 25ms/step - loss:
0.0345
Epoch 135/500
2/2             0s 25ms/step - loss:
0.0335
Epoch 136/500
2/2             0s 26ms/step - loss:
0.0320
Epoch 137/500
2/2             0s 27ms/step - loss:
0.0357
Epoch 138/500
2/2             0s 44ms/step - loss:
0.0346
Epoch 139/500
2/2             0s 25ms/step - loss:
0.0355
Epoch 140/500
2/2             0s 25ms/step - loss:
0.0223
Epoch 141/500
2/2             0s 26ms/step - loss:
0.0348
Epoch 142/500
2/2             0s 25ms/step - loss:
0.0260
Epoch 143/500
2/2             0s 26ms/step - loss:
0.0319
Epoch 144/500
2/2             0s 26ms/step - loss:
0.0333
Epoch 145/500
2/2             0s 24ms/step - loss:
0.0333
Epoch 146/500
2/2             0s 25ms/step - loss:
0.0234
Epoch 147/500
2/2             0s 27ms/step - loss:
0.0353
Epoch 148/500
```

```
2/2             0s 25ms/step - loss:
0.0242
Epoch 149/500
2/2             0s 33ms/step - loss:
0.0237
Epoch 150/500
2/2             0s 37ms/step - loss:
0.0324
Epoch 151/500
2/2             0s 26ms/step - loss:
0.0321
Epoch 152/500
2/2             0s 32ms/step - loss:
0.0334
Epoch 153/500
2/2             0s 26ms/step - loss:
0.0359
Epoch 154/500
2/2             0s 31ms/step - loss:
0.0218
Epoch 155/500
2/2             0s 26ms/step - loss:
0.0322
Epoch 156/500
2/2             0s 30ms/step - loss:
0.0299
Epoch 157/500
2/2             0s 27ms/step - loss:
0.0352
Epoch 158/500
2/2             0s 33ms/step - loss:
0.0236
Epoch 159/500
2/2             0s 25ms/step - loss:
0.0316
Epoch 160/500
2/2             0s 24ms/step - loss:
0.0230
Epoch 161/500
2/2             0s 25ms/step - loss:
0.0219
Epoch 162/500
2/2             0s 26ms/step - loss:
0.0320
Epoch 163/500
2/2             0s 26ms/step - loss:
0.0246
Epoch 164/500
```

```
2/2             0s 29ms/step - loss:
0.0314
Epoch 165/500
2/2             0s 25ms/step - loss:
0.0225
Epoch 166/500
2/2             0s 25ms/step - loss:
0.0321
Epoch 167/500
2/2             0s 26ms/step - loss:
0.0250
Epoch 168/500
2/2             0s 25ms/step - loss:
0.0323
Epoch 169/500
2/2             0s 35ms/step - loss:
0.0318
Epoch 170/500
2/2             0s 27ms/step - loss:
0.0241
Epoch 171/500
2/2             0s 25ms/step - loss:
0.0211
Epoch 172/500
2/2             0s 27ms/step - loss:
0.0314
Epoch 173/500
2/2             0s 25ms/step - loss:
0.0323
Epoch 174/500
2/2             0s 25ms/step - loss:
0.0321
Epoch 175/500
2/2             0s 26ms/step - loss:
0.0321
Epoch 176/500
2/2             0s 29ms/step - loss:
0.0313
Epoch 177/500
2/2             0s 31ms/step - loss:
0.0318
Epoch 178/500
2/2             0s 30ms/step - loss:
0.0313
Epoch 179/500
2/2             0s 26ms/step - loss:
0.0273
Epoch 180/500
```

```
2/2             0s 24ms/step - loss:
0.0345
Epoch 181/500
2/2             0s 26ms/step - loss:
0.0295
Epoch 182/500
2/2             0s 26ms/step - loss:
0.0353
Epoch 183/500
2/2             0s 27ms/step - loss:
0.0223
Epoch 184/500
2/2             0s 33ms/step - loss:
0.0229
Epoch 185/500
2/2             0s 26ms/step - loss:
0.0315
Epoch 186/500
2/2             0s 26ms/step - loss:
0.0225
Epoch 187/500
2/2             0s 27ms/step - loss:
0.0241
Epoch 188/500
2/2             0s 38ms/step - loss:
0.0221
Epoch 189/500
2/2             0s 26ms/step - loss:
0.0352
Epoch 190/500
2/2             0s 27ms/step - loss:
0.0230
Epoch 191/500
2/2             0s 26ms/step - loss:
0.0221
Epoch 192/500
2/2             0s 26ms/step - loss:
0.0305
Epoch 193/500
2/2             0s 26ms/step - loss:
0.0256
Epoch 194/500
2/2             0s 26ms/step - loss:
0.0213
Epoch 195/500
2/2             0s 27ms/step - loss:
0.0226
Epoch 196/500
```

```
2/2             0s 29ms/step - loss:
0.0351
Epoch 197/500
2/2             0s 28ms/step - loss:
0.0204
Epoch 198/500
2/2             0s 29ms/step - loss:
0.0232
Epoch 199/500
2/2             0s 25ms/step - loss:
0.0239
Epoch 200/500
2/2             0s 25ms/step - loss:
0.0317
Epoch 201/500
2/2             0s 26ms/step - loss:
0.0246
Epoch 202/500
2/2             0s 27ms/step - loss:
0.0346
Epoch 203/500
2/2             0s 26ms/step - loss:
0.0307
Epoch 204/500
2/2             0s 26ms/step - loss:
0.0221
Epoch 205/500
2/2             0s 28ms/step - loss:
0.0231
Epoch 206/500
2/2             0s 36ms/step - loss:
0.0308
Epoch 207/500
2/2             0s 31ms/step - loss:
0.0214
Epoch 208/500
2/2             0s 26ms/step - loss:
0.0205
Epoch 209/500
2/2             0s 25ms/step - loss:
0.0202
Epoch 210/500
2/2             0s 26ms/step - loss:
0.0283
Epoch 211/500
2/2             0s 28ms/step - loss:
0.0255
Epoch 212/500
```

```
2/2             0s 32ms/step - loss:
0.0250
Epoch 213/500
2/2             0s 26ms/step - loss:
0.0224
Epoch 214/500
2/2             0s 27ms/step - loss:
0.0229
Epoch 215/500
2/2             0s 25ms/step - loss:
0.0211
Epoch 216/500
2/2             0s 47ms/step - loss:
0.0338
Epoch 217/500
2/2             0s 48ms/step - loss:
0.0325
Epoch 218/500
2/2             0s 46ms/step - loss:
0.0311
Epoch 219/500
2/2             0s 42ms/step - loss:
0.0310
Epoch 220/500
2/2             0s 40ms/step - loss:
0.0207
Epoch 221/500
2/2             0s 44ms/step - loss:
0.0232
Epoch 222/500
2/2             0s 62ms/step - loss:
0.0222
Epoch 223/500
2/2             0s 63ms/step - loss:
0.0283
Epoch 224/500
2/2             0s 43ms/step - loss:
0.0309
Epoch 225/500
2/2             0s 41ms/step - loss:
0.0228
Epoch 226/500
2/2             0s 41ms/step - loss:
0.0309
Epoch 227/500
2/2             0s 42ms/step - loss:
0.0214
Epoch 228/500
```

```
2/2             0s 42ms/step - loss:
0.0227
Epoch 229/500
2/2             0s 63ms/step - loss:
0.0313
Epoch 230/500
2/2             0s 47ms/step - loss:
0.0190
Epoch 231/500
2/2             0s 43ms/step - loss:
0.0319
Epoch 232/500
2/2             0s 48ms/step - loss:
0.0358
Epoch 233/500
2/2             0s 28ms/step - loss:
0.0305
Epoch 234/500
2/2             0s 26ms/step - loss:
0.0240
Epoch 235/500
2/2             0s 25ms/step - loss:
0.0302
Epoch 236/500
2/2             0s 28ms/step - loss:
0.0185
Epoch 237/500
2/2             0s 29ms/step - loss:
0.0292
Epoch 238/500
2/2             0s 28ms/step - loss:
0.0299
Epoch 239/500
2/2             0s 26ms/step - loss:
0.0203
Epoch 240/500
2/2             0s 36ms/step - loss:
0.0222
Epoch 241/500
2/2             0s 27ms/step - loss:
0.0332
Epoch 242/500
2/2             0s 29ms/step - loss:
0.0316
Epoch 243/500
2/2             0s 28ms/step - loss:
0.0195
Epoch 244/500
```

```
2/2             0s 32ms/step - loss:
0.0292
Epoch 245/500
2/2             0s 27ms/step - loss:
0.0222
Epoch 246/500
2/2             0s 26ms/step - loss:
0.0253
Epoch 247/500
2/2             0s 30ms/step - loss:
0.0303
Epoch 248/500
2/2             0s 25ms/step - loss:
0.0256
Epoch 249/500
2/2             0s 30ms/step - loss:
0.0199
Epoch 250/500
2/2             0s 35ms/step - loss:
0.0203
Epoch 251/500
2/2             0s 30ms/step - loss:
0.0278
Epoch 252/500
2/2             0s 26ms/step - loss:
0.0288
Epoch 253/500
2/2             0s 27ms/step - loss:
0.0300
Epoch 254/500
2/2             0s 25ms/step - loss:
0.0336
Epoch 255/500
2/2             0s 26ms/step - loss:
0.0310
Epoch 256/500
2/2             0s 27ms/step - loss:
0.0161
Epoch 257/500
2/2             0s 25ms/step - loss:
0.0359
Epoch 258/500
2/2             0s 28ms/step - loss:
0.0291
Epoch 259/500
2/2             0s 31ms/step - loss:
0.0271
Epoch 260/500
```

```
2/2             0s 31ms/step - loss:
0.0239
Epoch 261/500
2/2             0s 27ms/step - loss:
0.0236
Epoch 262/500
2/2             0s 28ms/step - loss:
0.0328
Epoch 263/500
2/2             0s 28ms/step - loss:
0.0190
Epoch 264/500
2/2             0s 26ms/step - loss:
0.0268
Epoch 265/500
2/2             0s 25ms/step - loss:
0.0327
Epoch 266/500
2/2             0s 27ms/step - loss:
0.0156
Epoch 267/500
2/2             0s 38ms/step - loss:
0.0330
Epoch 268/500
2/2             0s 26ms/step - loss:
0.0285
Epoch 269/500
2/2             0s 29ms/step - loss:
0.0207
Epoch 270/500
2/2             0s 28ms/step - loss:
0.0201
Epoch 271/500
2/2             0s 28ms/step - loss:
0.0289
Epoch 272/500
2/2             0s 32ms/step - loss:
0.0211
Epoch 273/500
2/2             0s 27ms/step - loss:
0.0214
Epoch 274/500
2/2             0s 30ms/step - loss:
0.0206
Epoch 275/500
2/2             0s 35ms/step - loss:
0.0293
Epoch 276/500
```

```
2/2             0s 37ms/step - loss:
0.0232
Epoch 277/500
2/2             0s 29ms/step - loss:
0.0301
Epoch 278/500
2/2             0s 29ms/step - loss:
0.0200
Epoch 279/500
2/2             0s 26ms/step - loss:
0.0284
Epoch 280/500
2/2             0s 29ms/step - loss:
0.0278
Epoch 281/500
2/2             0s 27ms/step - loss:
0.0186
Epoch 282/500
2/2             0s 30ms/step - loss:
0.0252
Epoch 283/500
2/2             0s 30ms/step - loss:
0.0287
Epoch 284/500
2/2             0s 43ms/step - loss:
0.0278
Epoch 285/500
2/2             0s 27ms/step - loss:
0.0222
Epoch 286/500
2/2             0s 32ms/step - loss:
0.0337
Epoch 287/500
2/2             0s 26ms/step - loss:
0.0302
Epoch 288/500
2/2             0s 28ms/step - loss:
0.0309
Epoch 289/500
2/2             0s 28ms/step - loss:
0.0162
Epoch 290/500
2/2             0s 31ms/step - loss:
0.0184
Epoch 291/500
2/2             0s 28ms/step - loss:
0.0269
Epoch 292/500
```

```
2/2             0s 37ms/step - loss:
0.0268
Epoch 293/500
2/2             0s 30ms/step - loss:
0.0277
Epoch 294/500
2/2             0s 35ms/step - loss:
0.0144
Epoch 295/500
2/2             0s 29ms/step - loss:
0.0172
Epoch 296/500
2/2             0s 27ms/step - loss:
0.0310
Epoch 297/500
2/2             0s 28ms/step - loss:
0.0238
Epoch 298/500
2/2             0s 26ms/step - loss:
0.0280
Epoch 299/500
2/2             0s 28ms/step - loss:
0.0181
Epoch 300/500
2/2             0s 27ms/step - loss:
0.0249
Epoch 301/500
2/2             0s 36ms/step - loss:
0.0172
Epoch 302/500
2/2             0s 27ms/step - loss:
0.0165
Epoch 303/500
2/2             0s 30ms/step - loss:
0.0308
Epoch 304/500
2/2             0s 27ms/step - loss:
0.0130
Epoch 305/500
2/2             0s 34ms/step - loss:
0.0170
Epoch 306/500
2/2             0s 28ms/step - loss:
0.0158
Epoch 307/500
2/2             0s 26ms/step - loss:
0.0300
Epoch 308/500
```

```
2/2             0s 33ms/step - loss:
0.0348
Epoch 309/500
2/2             0s 27ms/step - loss:
0.0230
Epoch 310/500
2/2             0s 38ms/step - loss:
0.0232
Epoch 311/500
2/2             0s 27ms/step - loss:
0.0205
Epoch 312/500
2/2             0s 26ms/step - loss:
0.0221
Epoch 313/500
2/2             0s 31ms/step - loss:
0.0361
Epoch 314/500
2/2             0s 27ms/step - loss:
0.0168
Epoch 315/500
2/2             0s 29ms/step - loss:
0.0124
Epoch 316/500
2/2             0s 27ms/step - loss:
0.0271
Epoch 317/500
2/2             0s 33ms/step - loss:
0.0168
Epoch 318/500
2/2             0s 29ms/step - loss:
0.0144
Epoch 319/500
2/2             0s 29ms/step - loss:
0.0174
Epoch 320/500
2/2             0s 46ms/step - loss:
0.0209
Epoch 321/500
2/2             0s 40ms/step - loss:
0.0192
Epoch 322/500
2/2             0s 64ms/step - loss:
0.0549
Epoch 323/500
2/2             0s 46ms/step - loss:
0.0286
Epoch 324/500
```

```
2/2             0s 61ms/step - loss:
0.0202
Epoch 325/500
2/2             0s 47ms/step - loss:
0.0159
Epoch 326/500
2/2             0s 49ms/step - loss:
0.0184
Epoch 327/500
2/2             0s 42ms/step - loss:
0.0330
Epoch 328/500
2/2             0s 61ms/step - loss:
0.0195
Epoch 329/500
2/2             0s 43ms/step - loss:
0.0178
Epoch 330/500
2/2             0s 45ms/step - loss:
0.0253
Epoch 331/500
2/2             0s 41ms/step - loss:
0.0263
Epoch 332/500
2/2             0s 43ms/step - loss:
0.0266
Epoch 333/500
2/2             0s 47ms/step - loss:
0.0209
Epoch 334/500
2/2             0s 51ms/step - loss:
0.0355
Epoch 335/500
2/2             0s 55ms/step - loss:
0.0150
Epoch 336/500
2/2             0s 79ms/step - loss:
0.0145
Epoch 337/500
2/2             0s 59ms/step - loss:
0.0202
Epoch 338/500
2/2             0s 49ms/step - loss:
0.0170
Epoch 339/500
2/2             0s 31ms/step - loss:
0.0166
Epoch 340/500
```

```
2/2             0s 33ms/step - loss:
0.0208
Epoch 341/500
2/2             0s 26ms/step - loss:
0.0207
Epoch 342/500
2/2             0s 27ms/step - loss:
0.0283
Epoch 343/500
2/2             0s 38ms/step - loss:
0.0155
Epoch 344/500
2/2             0s 28ms/step - loss:
0.0310
Epoch 345/500
2/2             0s 33ms/step - loss:
0.0242
Epoch 346/500
2/2             0s 32ms/step - loss:
0.0172
Epoch 347/500
2/2             0s 29ms/step - loss:
0.0233
Epoch 348/500
2/2             0s 30ms/step - loss:
0.0128
Epoch 349/500
2/2             0s 27ms/step - loss:
0.0173
Epoch 350/500
2/2             0s 28ms/step - loss:
0.0239
Epoch 351/500
2/2             0s 34ms/step - loss:
0.0197
Epoch 352/500
2/2             0s 41ms/step - loss:
0.0219
Epoch 353/500
2/2             0s 28ms/step - loss:
0.0283
Epoch 354/500
2/2             0s 27ms/step - loss:
0.0164
Epoch 355/500
2/2             0s 27ms/step - loss:
0.0190
Epoch 356/500
```

```
2/2             0s 28ms/step - loss:
0.0243
Epoch 357/500
2/2             0s 28ms/step - loss:
0.0186
Epoch 358/500
2/2             0s 36ms/step - loss:
0.0235
Epoch 359/500
2/2             0s 29ms/step - loss:
0.0183
Epoch 360/500
2/2             0s 40ms/step - loss:
0.0129
Epoch 361/500
2/2             0s 38ms/step - loss:
0.0168
Epoch 362/500
2/2             0s 28ms/step - loss:
0.0222
Epoch 363/500
2/2             0s 30ms/step - loss:
0.0257
Epoch 364/500
2/2             0s 31ms/step - loss:
0.0157
Epoch 365/500
2/2             0s 28ms/step - loss:
0.0229
Epoch 366/500
2/2             0s 32ms/step - loss:
0.0334
Epoch 367/500
2/2             0s 38ms/step - loss:
0.0179
Epoch 368/500
2/2             0s 30ms/step - loss:
0.0137
Epoch 369/500
2/2             0s 29ms/step - loss:
0.0139
Epoch 370/500
2/2             0s 34ms/step - loss:
0.0235
Epoch 371/500
2/2             0s 29ms/step - loss:
0.0172
Epoch 372/500
```

```
2/2             0s 29ms/step - loss:
0.0246
Epoch 373/500
2/2             0s 28ms/step - loss:
0.0280
Epoch 374/500
2/2             0s 31ms/step - loss:
0.0183
Epoch 375/500
2/2             0s 32ms/step - loss:
0.0283
Epoch 376/500
2/2             0s 31ms/step - loss:
0.0125
Epoch 377/500
2/2             0s 34ms/step - loss:
0.0204
Epoch 378/500
2/2             0s 41ms/step - loss:
0.0189
Epoch 379/500
2/2             0s 28ms/step - loss:
0.0113
Epoch 380/500
2/2             0s 33ms/step - loss:
0.0301
Epoch 381/500
2/2             0s 30ms/step - loss:
0.0175
Epoch 382/500
2/2             0s 27ms/step - loss:
0.0290
Epoch 383/500
2/2             0s 30ms/step - loss:
0.0162
Epoch 384/500
2/2             0s 35ms/step - loss:
0.0285
Epoch 385/500
2/2             0s 29ms/step - loss:
0.0185
Epoch 386/500
2/2             0s 37ms/step - loss:
0.0146
Epoch 387/500
2/2             0s 31ms/step - loss:
0.0183
Epoch 388/500
```

```
2/2             0s 30ms/step - loss:
0.0186
Epoch 389/500
2/2             0s 29ms/step - loss:
0.0181
Epoch 390/500
2/2             0s 31ms/step - loss:
0.0210
Epoch 391/500
2/2             0s 28ms/step - loss:
0.0186
Epoch 392/500
2/2             0s 31ms/step - loss:
0.0309
Epoch 393/500
2/2             0s 35ms/step - loss:
0.0261
Epoch 394/500
2/2             0s 42ms/step - loss:
0.0265
Epoch 395/500
2/2             0s 38ms/step - loss:
0.0128
Epoch 396/500
2/2             0s 28ms/step - loss:
0.0206
Epoch 397/500
2/2             0s 28ms/step - loss:
0.0143
Epoch 398/500
2/2             0s 30ms/step - loss:
0.0151
Epoch 399/500
2/2             0s 30ms/step - loss:
0.0144
Epoch 400/500
2/2             0s 30ms/step - loss:
0.0121
Epoch 401/500
2/2             0s 29ms/step - loss:
0.0118
Epoch 402/500
2/2             0s 32ms/step - loss:
0.0137
Epoch 403/500
2/2             0s 38ms/step - loss:
0.0266
Epoch 404/500
```

```
2/2             0s 34ms/step - loss:
0.0234
Epoch 405/500
2/2             0s 31ms/step - loss:
0.0179
Epoch 406/500
2/2             0s 28ms/step - loss:
0.0237
Epoch 407/500
2/2             0s 29ms/step - loss:
0.0237
Epoch 408/500
2/2             0s 30ms/step - loss:
0.0146
Epoch 409/500
2/2             0s 29ms/step - loss:
0.0166
Epoch 410/500
2/2             0s 31ms/step - loss:
0.0207
Epoch 411/500
2/2             0s 41ms/step - loss:
0.0192
Epoch 412/500
2/2             0s 34ms/step - loss:
0.0182
Epoch 413/500
2/2             0s 29ms/step - loss:
0.0253
Epoch 414/500
2/2             0s 32ms/step - loss:
0.0169
Epoch 415/500
2/2             0s 31ms/step - loss:
0.0199
Epoch 416/500
2/2             0s 28ms/step - loss:
0.0141
Epoch 417/500
2/2             0s 35ms/step - loss:
0.0213
Epoch 418/500
2/2             0s 28ms/step - loss:
0.0284
Epoch 419/500
2/2             0s 36ms/step - loss:
0.0233
Epoch 420/500
```

```
2/2             0s 27ms/step - loss:
0.0185
Epoch 421/500
2/2             0s 28ms/step - loss:
0.0231
Epoch 422/500
2/2             0s 43ms/step - loss:
0.0235
Epoch 423/500
2/2             0s 64ms/step - loss:
0.0163
Epoch 424/500
2/2             0s 38ms/step - loss:
0.0196
Epoch 425/500
2/2             0s 45ms/step - loss:
0.0118
Epoch 426/500
2/2             0s 57ms/step - loss:
0.0203
Epoch 427/500
2/2             0s 44ms/step - loss:
0.0190
Epoch 428/500
2/2             0s 64ms/step - loss:
0.0218
Epoch 429/500
2/2             0s 38ms/step - loss:
0.0112
Epoch 430/500
2/2             0s 44ms/step - loss:
0.0191
Epoch 431/500
2/2             0s 49ms/step - loss:
0.0119
Epoch 432/500
2/2             0s 43ms/step - loss:
0.0193
Epoch 433/500
2/2             0s 48ms/step - loss:
0.0161
Epoch 434/500
2/2             0s 40ms/step - loss:
0.0189
Epoch 435/500
2/2             0s 47ms/step - loss:
0.0106
Epoch 436/500
```

```
2/2             0s 56ms/step - loss:
0.0196
Epoch 437/500
2/2             0s 50ms/step - loss:
0.0160
Epoch 438/500
2/2             0s 43ms/step - loss:
0.0142
Epoch 439/500
2/2             0s 48ms/step - loss:
0.0209
Epoch 440/500
2/2             0s 31ms/step - loss:
0.0216
Epoch 441/500
2/2             0s 28ms/step - loss:
0.0230
Epoch 442/500
2/2             0s 34ms/step - loss:
0.0208
Epoch 443/500
2/2             0s 32ms/step - loss:
0.0160
Epoch 444/500
2/2             0s 42ms/step - loss:
0.0198
Epoch 445/500
2/2             0s 32ms/step - loss:
0.0117
Epoch 446/500
2/2             0s 33ms/step - loss:
0.0198
Epoch 447/500
2/2             0s 35ms/step - loss:
0.0169
Epoch 448/500
2/2             0s 28ms/step - loss:
0.0099
Epoch 449/500
2/2             0s 28ms/step - loss:
0.0202
Epoch 450/500
2/2             0s 32ms/step - loss:
0.0177
Epoch 451/500
2/2             0s 29ms/step - loss:
0.0109
Epoch 452/500
```

```
2/2             0s 29ms/step - loss:
0.0179
Epoch 453/500
2/2             0s 30ms/step - loss:
0.0160
Epoch 454/500
2/2             0s 38ms/step - loss:
0.0185
Epoch 455/500
2/2             0s 30ms/step - loss:
0.0153
Epoch 456/500
2/2             0s 46ms/step - loss:
0.0107
Epoch 457/500
2/2             0s 30ms/step - loss:
0.0178
Epoch 458/500
2/2             0s 34ms/step - loss:
0.0175
Epoch 459/500
2/2             0s 33ms/step - loss:
0.0193
Epoch 460/500
2/2             0s 32ms/step - loss:
0.0172
Epoch 461/500
2/2             0s 31ms/step - loss:
0.0154
Epoch 462/500
2/2             0s 40ms/step - loss:
0.0128
Epoch 463/500
2/2             0s 34ms/step - loss:
0.0135
Epoch 464/500
2/2             0s 30ms/step - loss:
0.0168
Epoch 465/500
2/2             0s 33ms/step - loss:
0.0148
Epoch 466/500
2/2             0s 27ms/step - loss:
0.0193
Epoch 467/500
2/2             0s 34ms/step - loss:
0.0175
Epoch 468/500
```

```
2/2             0s 31ms/step - loss:
0.0121
Epoch 469/500
2/2             0s 42ms/step - loss:
0.0143
Epoch 470/500
2/2             0s 29ms/step - loss:
0.0083
Epoch 471/500
2/2             0s 37ms/step - loss:
0.0146
Epoch 472/500
2/2             0s 43ms/step - loss:
0.0132
Epoch 473/500
2/2             0s 32ms/step - loss:
0.0163
Epoch 474/500
2/2             0s 37ms/step - loss:
0.0181
Epoch 475/500
2/2             0s 32ms/step - loss:
0.0116
Epoch 476/500
2/2             0s 31ms/step - loss:
0.0059
Epoch 477/500
2/2             0s 32ms/step - loss:
0.0078
Epoch 478/500
2/2             0s 38ms/step - loss:
0.0161
Epoch 479/500
2/2             0s 28ms/step - loss:
0.0092
Epoch 480/500
2/2             0s 28ms/step - loss:
0.0211
Epoch 481/500
2/2             0s 31ms/step - loss:
0.0167
Epoch 482/500
2/2             0s 31ms/step - loss:
0.0069
Epoch 483/500
2/2             0s 28ms/step - loss:
0.0204
Epoch 484/500
```

```
2/2             0s 28ms/step - loss:
0.0142
Epoch 485/500
2/2             0s 31ms/step - loss:
0.0115
Epoch 486/500
2/2             0s 29ms/step - loss:
0.0131
Epoch 487/500
2/2             0s 36ms/step - loss:
0.0025
Epoch 488/500
2/2             0s 41ms/step - loss:
0.0206
Epoch 489/500
2/2             0s 32ms/step - loss:
0.0162
Epoch 490/500
2/2             0s 34ms/step - loss:
0.0057
Epoch 491/500
2/2             0s 28ms/step - loss:
0.0118
Epoch 492/500
2/2             0s 35ms/step - loss:
0.0139
Epoch 493/500
2/2             0s 29ms/step - loss:
0.0087
Epoch 494/500
2/2             0s 30ms/step - loss:
0.0110
Epoch 495/500
2/2             0s 33ms/step - loss:
0.0098
Epoch 496/500
2/2             0s 40ms/step - loss:
0.0098
Epoch 497/500
2/2             0s 36ms/step - loss:
0.0030
Epoch 498/500
2/2             0s 33ms/step - loss:
0.0114
Epoch 499/500
2/2             0s 28ms/step - loss:
0.0087
Epoch 500/500
```

```
2/2             0s 28ms/step - loss:
0.0031
```

[91]:
```python
# Última secuencia para cada variable para iniciar la predicción futura
last_sequence_accesos = scaler_accesos.transform(
    bogota_data_accesos_2['No. ACCESOS FIJOS A INTERNET'].values[-4:].
 ↪reshape(-1, 1)
).reshape(1, 4, 1)
```

[92]:
```python
# Predicciones en el conjunto de prueba
y_pred_train = model_accesos.predict(X_accesos)
```

```
1/1             1s 792ms/step
```

[93]:
```python
# Invertir escalado
y_pred_train = scaler_accesos.inverse_transform(y_pred_train)
y_train_actual = scaler_accesos.inverse_transform(y_accesos.reshape(-1, 1))
```

[94]:
```python
# Calcular métricas
mse = mean_squared_error(y_train_actual, y_pred_train)
mae = mean_absolute_error(y_train_actual, y_pred_train)
r2 = r2_score(y_train_actual, y_pred_train)
```

[95]:
```python
print("Métricas del modelo LSTM para No. ACCESOS FIJOS A INTERNET:")
print(f"MSE: {mse:.4f}")
print(f"MAE: {mae:.4f}")
print(f"R²: {r2:.4f}")
```

```
Métricas del modelo LSTM para No. ACCESOS FIJOS A INTERNET:
MSE: 9927139019.1992
MAE: 44901.3348
R²: 0.7813
```

[96]:
```python
# Predicciones futuras para Acceso a Internet
def predict_future_lstm(model, scaler, last_sequence, future_steps=9):
    future_predictions = []
    for _ in range(future_steps):
        # Realizar la predicción actual
        prediction = model.predict(last_sequence)

        # Invertir el escalado de la predicción
        scaled_prediction = scaler.inverse_transform(prediction)

        # Redondear al entero más cercano
        rounded_prediction = np.round(scaled_prediction).astype(int)

        # Guardar la predicción actual
        future_predictions.append(rounded_prediction[0, 0])
```

```
        # Expandir las dimensiones de la predicción
        prediction_expanded = np.expand_dims(prediction, axis=0)

        # Modificar el último conjunto de datos
        last_sequence = np.append(last_sequence[:, 1:, :], prediction_expanded,␣
 ↪axis=1)

    return np.array(future_predictions).reshape(-1, 1)
```

[97]:
```
predictions_accesos = predict_future_lstm(model_accesos, scaler_accesos,␣
 ↪last_sequence_accesos, future_steps=9)

# Crear DataFrames para las predicciones
future_accesos_df = pd.DataFrame(predictions_accesos, index=future_dates,␣
 ↪columns=['Predicción No. ACCESOS FIJOS A INTERNET'])

# Crear un DataFrame para los trimestres futuros y agregar las predicciones
future_data = pd.DataFrame(index=future_dates)
future_data['AÑO_TRIMESTRE'] = future_trimestres
future_data['No. ACCESOS FIJOS A INTERNET'] = future_accesos_df['Predicción No.␣
 ↪ACCESOS FIJOS A INTERNET'].values

# Mostrar el DataFrame combinado con predicciones futuras
print("\nPredicciones Futuras:")
print(future_data)
```

```
1/1             1s 573ms/step
1/1             0s 23ms/step
1/1             0s 25ms/step
1/1             0s 23ms/step
1/1             0s 24ms/step
1/1             0s 30ms/step
1/1             0s 22ms/step
1/1             0s 26ms/step
1/1             0s 26ms/step

Predicciones Futuras:
            AÑO_TRIMESTRE  No. ACCESOS FIJOS A INTERNET
2023-04-01         202304                       2293552
2024-01-01         202401                       2288125
2024-02-01         202402                       2287426
2024-03-01         202403                       2288684
2024-04-01         202404                       2292099
2025-01-01         202501                       2291784
2025-02-01         202502                       2292595
2025-03-01         202503                       2293302
```

2025-04-01 202504 2293761

[98]:
```
# Visualización de resultados
plt.figure(figsize=(10, 6))
plt.plot(y_train_actual, label='Valores Reales')
plt.plot(y_pred_train, label='Predicciones en Entrenamiento')
plt.title('Desempeño del Modelo LSTM')
plt.xlabel('Trimestres')
plt.ylabel('Accesos Fijos a Internet')
plt.legend()
plt.show()

# Visualizar predicciones futuras
plt.figure(figsize=(10, 6))
plt.plot(future_dates, future_data['No. ACCESOS FIJOS A INTERNET'],␣
 ↪label='Predicciones Futuras', linestyle='--')
plt.title('Predicción de Accesos Fijos a Internet (Trimestres Futuros)')
plt.xlabel('Trimestre')
plt.ylabel('Accesos Fijos a Internet')
plt.legend()
plt.show()
```

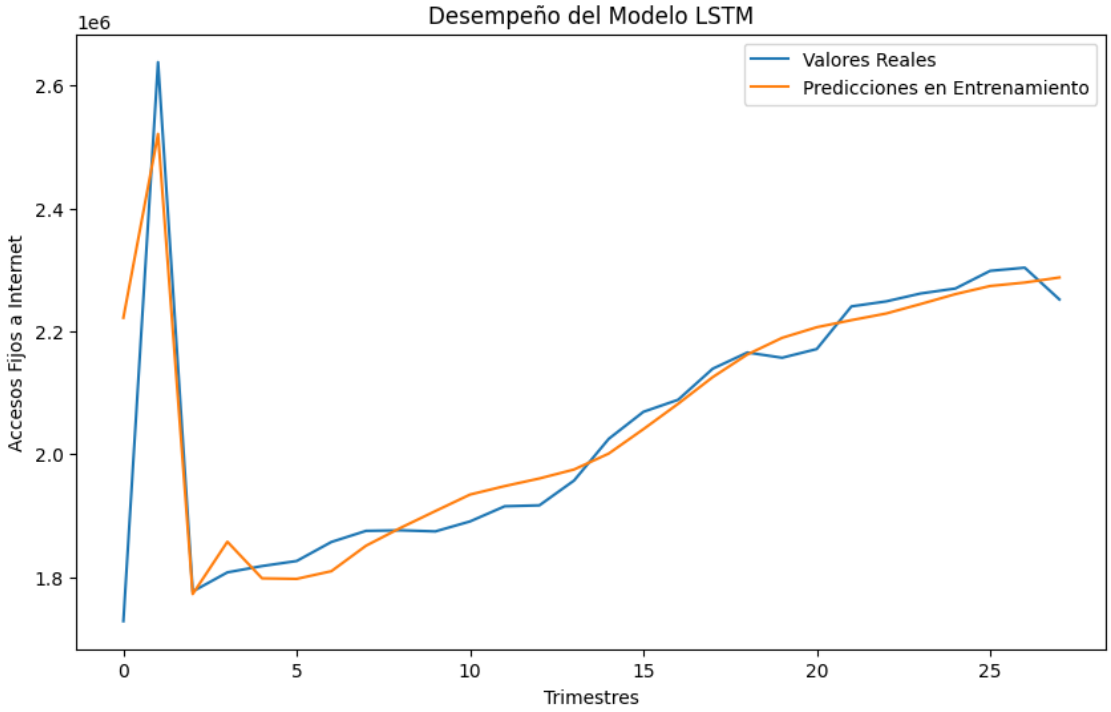

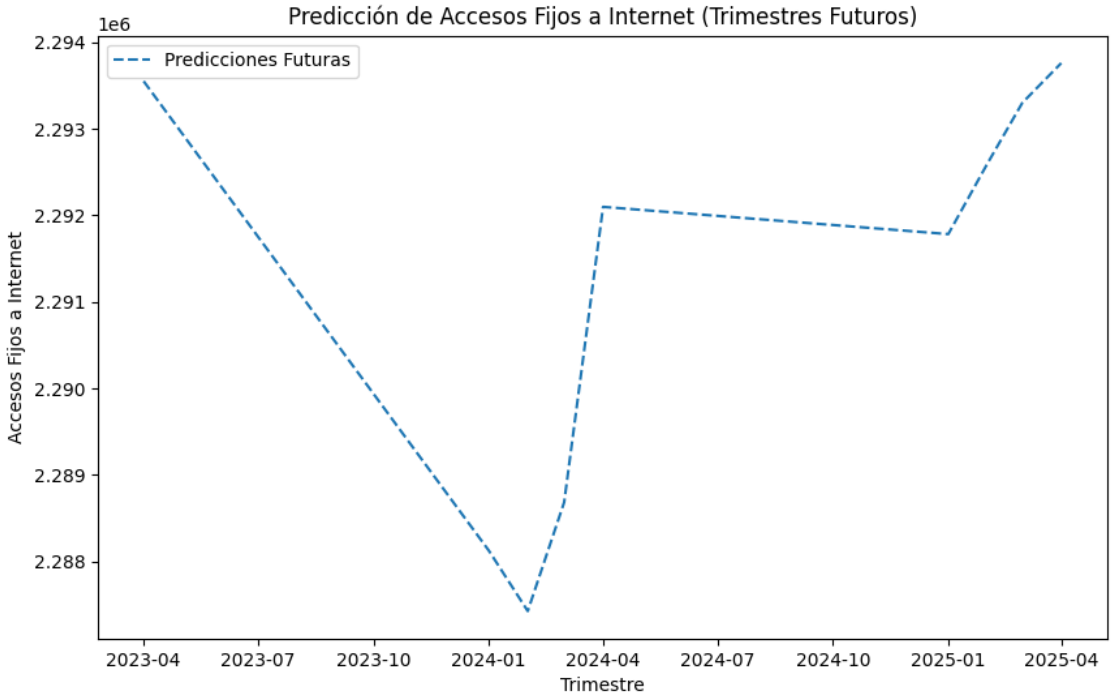

7 Conclusiones Basadas en las Métricas y Predicciones Futuras

1. **Desempeño del Modelo LSTM**:
    1. El modelo muestra un **MSE (Error Cuadrático Medio)** de **9,927,139,019.1992**, evidenciando una mejora significativa en comparación con iteraciones anteriores.
    2. El **MAE (Error Absoluto Medio)** es de **44,901.3348**, indicando que el modelo ha reducido considerablemente el error promedio entre las predicciones y los valores reales.
    3. El **coeficiente R^2** de **0.7813** refleja que el modelo explica el 78.13% de la variabi

[100]:
```
print("Métricas del modelo LSTM para No. ACCESOS FIJOS A INTERNET:")
print(f"MSE: {mse:.4f}")
print(f"MAE: {mae:.4f}")
print(f"R²: {r2:.4f}")
```

```
Métricas del modelo LSTM para No. ACCESOS FIJOS A INTERNET:
MSE: 9927139019.1992
MAE: 44901.3348
R²: 0.7813
```

1. **Predicciones Futuras**:
    1. Las proyecciones predicen un comportamiento **estable y ligeramente creciente para los accesos fijos a internet** en los años 2024 y 2025, con valores que oscilan entre **2,287,426 y 2,293,761 accesos**.
    2. La estabilidad en los valores predichos sugiere que el modelo ha capturado mejor los patrones subyacentes de los datos.

2. **Observaciones Clave**:
    1. Aunque el modelo ha mejorado significativamente, aún existe un margen de error que podría reducirse incorporando más datos o ajustando los parámetros del modelo.
    2. La capacidad del modelo para predecir tendencias generales es sólida, pero podría ser vulnerable a cambios inesperados en las condiciones externas.

7.0.1 Predicción de Accesos Fijos a Internet:

Los valores proyectados indican un comportamiento estable con un ligero aumento durante los años 2024 y 2025, con algunas fluctuaciones menores:

- En el primer trimestre de 2024, el número de accesos se predice en 2,288,125.
- Durante los trimestres siguientes de 2024, los accesos fluctúan ligeramente, alcanzando un mínimo de 2,287,426 en el segundo trimestre y recuperándose a 2,292,099 para el cuarto trimestre.

2025:

- En 2025, se observa una tendencia de estabilidad en los accesos fijos, con valores cercanos a los 2,293,761 en el cuarto trimestre.
- Los accesos muestran una ligera variación, alcanzando 2,292,595 en el segundo trimestre y manteniéndose en 2,293,302 en el tercer trimestre. ### **Resumen:**
- **2024:** Fluctuaciones menores con una tendencia general estable, alcanzando 2,292,099 accesos en el cuarto trimestre.
- **2025:** Estabilización cercana a los 2,293,761 accesos en el cuarto trimestre.

Estas proyecciones sugieren un comportamiento consistente en los accesos fijos a internet, lo que proporciona una base sólida para la planificación estratégica y la toma de decisiones.

7.0.2 Visualización de las Predicciones Futuras:

En la gráfica correspondiente a las predicciones de accesos fijos a internet para los años 2024 y 2025, los valores proyectados presentan las siguientes características:

- **Inicio de 2024:** Se observa una ligera disminución en el número de accesos, comenzando con 2,288,125 accesos en el primer trimestre y alcanzando un mínimo de 2,287,426 accesos en el segundo trimestre.
- **Tercer Trimestre de 2024:** A partir del tercer trimestre, los accesos comienzan a recuperarse, alcanzando 2,288,684.
- **Cuarto Trimestre de 2024:** La recuperación continúa, culminando en 2,292,099 accesos.
- **Año 2025:** Durante 2025, los accesos muestran un comportamiento estable, con valores proyectados de 2,291,784 en el primer trimestre, 2,292,595 en el segundo trimestre, 2,293,302 en el tercer trimestre y 2,293,761 en el cuarto trimestre. ### **Resultados de la Gráfica**

AÑO_TRIMESTRE	No. ACCESOS FIJOS A INTERNET
2023-04	2,293,552
2024-01	2,288,125
2024-02	2,287,426
2024-03	2,288,684
2024-04	2,292,099

AÑO_TRIMESTRE	No. ACCESOS FIJOS A INTERNET
2025-01	2,291,784
2025-02	2,292,595
2025-03	2,293,302
2025-04	2,293,761

Resumen:

- **Inicio de 2024:** Ligera disminución en los accesos fijos, alcanzando un mínimo en el segundo trimestre.
- **Cuarto Trimestre de 2024:** Recuperación notable, con una estabilización en los accesos a lo largo de 2025.
- **2025:** Estabilización de los accesos fijos, manteniéndose alrededor de 2.293 millones en los trimestres futuros.

7.0.3 Recomendaciones

1. Optimización del Modelo

- **Refinamiento de Hiperparámetros**:
  - Ajustar los parámetros como la tasa de aprendizaje, número de épocas y tamaño de lotes para buscar una mejora adicional en las métricas.
- **Exploración de Otros Modelos**:
  - Evaluar el uso de arquitecturas GRU o modelos híbridos (como LSTM con capas densas) para comparar el rendimiento.

2. Inclusión de Datos Adicionales - Incorporar variables externas que puedan mejorar el contexto de las predicciones, como: - Factores económicos (PIB, ingresos promedio). - Cambios tecnológicos o regulatorios en el sector de telecomunicaciones. - Dinámica poblacional en áreas clave.

3. Análisis de Tendencias y Validación - Validación Continua: - Comparar las predicciones con los valores reales trimestralmente para verificar la precisión y ajustar el modelo en caso necesario. - Análisis de Escenarios: - Generar diferentes escenarios de predicción (base, optimista y pesimista) para analizar posibles fluctuaciones en los accesos.**

4. Estrategias Comerciales y de Expansión

- Utilizar los resultados de las predicciones para planificar estrategias de crecimiento, como:
  - Ofertas y promociones que aumenten la penetración de internet fijo.
  - Ampliación de infraestructura en regiones con menor penetración.

5. Monitoreo de Factores Externos

- Mantener un seguimiento constante de eventos externos que puedan impactar las predicciones, como cambios regulatorios, eventos económicos globales

Para finalizar actualizamos la informacion y damos algunos indices y visualizacion de la informacion

[104]:
```
bogota_data_prediction = bogota_data_combined.copy()
# Unir las predicciones futuras al DataFrame combinado
# Código generado por Gemini
bogota_data_prediction.update(future_data)
```

[105]:
```
# Calcular el índice y agregarlo al DataFrame
bogota_data_prediction['INDICE(%)'] = ( bogota_data_prediction['No. ACCESOS␣
 ↪FIJOS A INTERNET'] / bogota_data_prediction['POBLACIÓN DANE'] ) * 100
```

[107]:
```
# Mostrar el DataFrame combinado con predicciones futuras y el índice calculado
print("\nDataFrame Combinado con Predicciones Futuras:")
print(bogota_data_prediction)
```

```
DataFrame Combinado con Predicciones Futuras:
   AÑO_TRIMESTRE  No. ACCESOS FIJOS A INTERNET  POBLACIÓN DANE  INDICE(%)
0         201504                       1610511         7273265  22.142889
1         201601                       1647186         7300918  22.561355
2         201602                       1681117         7300918  23.026104
3         201603                       1719075         7300918  23.546012
4         201604                       1728459         7300918  23.674543
5         201701                       2638171         7337449  35.954880
6         201702                       1776768         7337449  24.215064
7         201703                       1807827         7337449  24.638359
8         201704                       1818094         7337449  24.778285
9         201801                       1826350         7412566  24.638566
10        201802                       1857309         7412566  25.056222
11        201803                       1875396         7412566  25.300227
12        201804                       1876271         7412566  25.312031
13        201901                       1874506         7592871  24.687710
14        201902                       1890765         7592871  24.901845
15        201903                       1915409         7592871  25.226413
16        201904                       1916910         7592871  25.246182
17        202001                       1957333         7732161  25.314178
18        202002                       2025140         7732161  26.191126
19        202003                       2069115         7732161  26.759854
20        202004                       2088680         7732161  27.012888
21        202101                       2139304         7823334  27.345170
22        202102                       2165658         7823334  27.682034
23        202103                       2157112         7823334  27.572797
24        202104                       2171274         7823334  27.753820
25        202201                       2240695         7873316  28.459356
26        202202                       2248809         7873316  28.562413
27        202203                       2261755         7873316  28.726841
28        202204                       2269823         7873316  28.829314
29        202301                       2298520         7907281  29.068399
```

30	202302	2303696	7907281	29.133858
31	202303	2251960	7907281	28.479575
32	202304	2344009	7897196	29.681535
33	202401	2377140	7903749	30.076107
34	202402	2430805	7903220	30.757147
35	202403	2499196	7902434	31.625649
36	202404	2598602	7901166	32.888842
37	202501	2726560	7902321	34.503281
38	202502	2907224	7902062	36.790701
39	202503	3165489	7901823	40.060237
40	202504	3540324	7901688	44.804654

[108]:
```
# Guardar el DataFrame actualizado en un archivo CSV
bogota_data_prediction.to_csv('bogota_data_prediction.csv', index=False)

# Descargar el archivo CSV generado
from google.colab import files
files.download('bogota_data_prediction.csv')
```

```
<IPython.core.display.Javascript object>
```

```
<IPython.core.display.Javascript object>
```

[110]:
```
import matplotlib.pyplot as plt

# Filtrar los datos desde el 202401 hasta el 202504
df_filtered = bogota_data_prediction[bogota_data_prediction['AÑO_TRIMESTRE'].
 ↪between('202401', '202504')]

# Graficar las predicciones combinadas de accesos fijos a internet y población␣
 ↪DANE
plt.figure(figsize=(14, 6))

# Graficar el número de accesos fijos a internet
plt.plot(df_filtered['AÑO_TRIMESTRE'], df_filtered['No. ACCESOS FIJOS A␣
 ↪INTERNET'], label='No. ACCESOS FIJOS A INTERNET', marker='o')

# Graficar la población DANE
plt.plot(df_filtered['AÑO_TRIMESTRE'], df_filtered['POBLACIÓN DANE'],␣
 ↪label='POBLACIÓN DANE', marker='x')

# Agregar anotaciones de millones en cada punto predicho de accesos
for i, txt in enumerate(df_filtered['No. ACCESOS FIJOS A INTERNET']):
    plt.annotate(f'{txt/1e6:.1f}M', (df_filtered['AÑO_TRIMESTRE'].values[i],␣
 ↪txt), textcoords="offset points", xytext=(0,10), ha='center', fontsize=8)

# Agregar anotaciones de millones en cada punto predicho de población
for i, txt in enumerate(df_filtered['POBLACIÓN DANE']):
```

```
    plt.annotate(f'{txt/1e6:.1f}M', (df_filtered['AÑO_TRIMESTRE'].values[i],␣
 ↪txt), textcoords="offset points", xytext=(0,10), ha='center', fontsize=8)

plt.title('Predicción de No. ACCESOS FIJOS A INTERNET y POBLACIÓN DANE (202401␣
 ↪- 202504)')
plt.xlabel('Año-Trimestre')
plt.ylabel('Valores (millones)')
plt.legend()
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout()
plt.show()
```

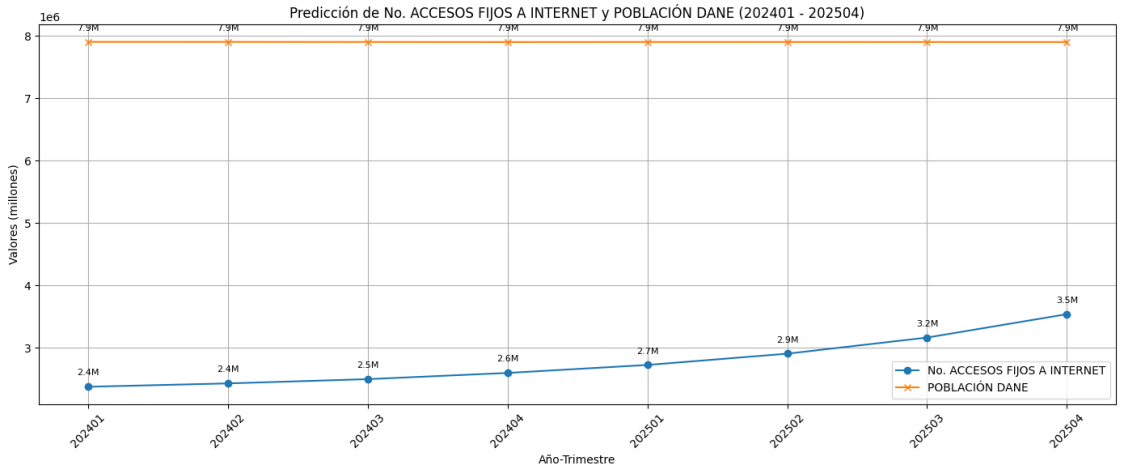

[113]:
```
# Calcular el índice
bogota_data_combined['INDICE(%)'] = (bogota_data_combined['No. ACCESOS FIJOS A␣
 ↪INTERNET'] / bogota_data_combined['POBLACIÓN DANE']) * 100

# Filtrar los datos desde el 202401 hasta el 202504
df_filtered = bogota_data_combined[bogota_data_combined['AÑO_TRIMESTRE'].
 ↪between('202401', '202504')]

# Graficar las predicciones combinadas de accesos fijos a internet y población␣
 ↪DANE
plt.figure(figsize=(14, 6))

# Graficar el número de accesos fijos a internet
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'], bogota_data_combined['No.␣
 ↪ACCESOS FIJOS A INTERNET'], label='No. ACCESOS FIJOS A INTERNET', marker='o')

# Graficar la población DANE
```

```
plt.plot(bogota_data_combined['AÑO_TRIMESTRE'], bogota_data_combined['POBLACIÓN␣
 ↪DANE'], label='POBLACIÓN DANE', marker='x')

# Agregar anotaciones de millones en cada punto predicho de accesos desde␣
 ↪202401 hasta 202504
for i, txt in enumerate(df_filtered['No. ACCESOS FIJOS A INTERNET']):
    plt.annotate(f'{txt/1e6:.1f}M', (df_filtered['AÑO_TRIMESTRE'].values[i],␣
 ↪txt), textcoords="offset points", xytext=(0,10), ha='center', fontsize=8)

# Agregar anotaciones de millones en cada punto predicho de población desde␣
 ↪202401 hasta 202504
for i, txt in enumerate(df_filtered['POBLACIÓN DANE']):
    plt.annotate(f'{txt/1e6:.1f}M', (df_filtered['AÑO_TRIMESTRE'].values[i],␣
 ↪txt), textcoords="offset points", xytext=(0,10), ha='center', fontsize=8)

plt.title('Predicción de No. ACCESOS FIJOS A INTERNET y POBLACIÓN DANE')
plt.xlabel('Año-Trimestre')
plt.ylabel('Valores (millones)')
plt.ylim(0, 9000000)  # Ajustar el eje Y para que llegue a 9 millones
plt.legend(loc='upper center', bbox_to_anchor=(0.5, -0.15), ncol=2)  # Mover la␣
 ↪leyenda debajo del gráfico
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout()
plt.show()
```

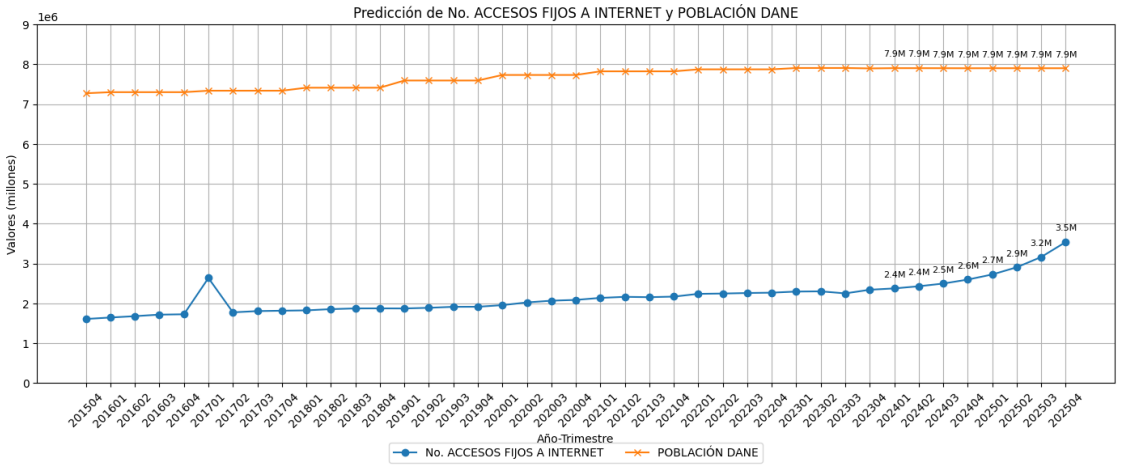

7.0.4 Conclusiones Adicionales

1. **Tendencia General de Crecimiento:**
    1. La gráfica muestra un incremento notable en el número de accesos fijos a internet a lo largo de los trimestres. Este aumento es especialmente pronunciado a partir de 2020, lo

que sugiere una mayor adopción de servicios de internet en la población.

2. **Comparación de Crecimientos:**
    1. Mientras que la población DANE ha crecido de manera relativamente estable, el número de accesos a internet ha experimentado un crecimiento mucho más acelerado. Esto indica un aumento en la penetración del internet en la población.
3. **Impacto de la Pandemia:**
    1. El crecimiento acelerado en los accesos a internet a partir de 2020 podría estar relacionado con la pandemia de COVID-19, que impulsó la demanda de servicios de internet debido al teletrabajo, la educación en línea y el entretenimiento en el hogar.
4. **Estabilización Futura:**
    1. Las proyecciones futuras hasta el cuarto trimestre de 2025 sugieren una estabilización en el crecimiento de accesos fijos a internet, mientras que la población DANE se mantendrá estable en torno a los 7.9 millones. Esta estabilización podría indicar un mercado maduro con una alta penetración de internet.
5. **Incremento en el Índice de Penetración:**
    1. El índice de penetración (% de accesos fijos a internet respecto a la población) ha aumentado significativamente, lo que refleja la creciente importancia del acceso a internet en la vida cotidiana de la población.
6. **Proyecciones Positivas:**
    1. La proyección sugiere que para finales de 2025, el número de accesos fijos a internet continuará en aumento, superando los 3.5 millones, mientras que la población DANE se mantendrá constante. Este crecimiento en los accesos muestra la consolidación del internet como una necesidad básica.

7.0.5 Recomendaciones Estratégicas

1. **Ampliación de Infraestructura:**
    1. Dado el crecimiento continuo en los accesos a internet, es crucial seguir invirtiendo en la infraestructura de telecomunicaciones para asegurar una cobertura adecuada y de alta calidad en todo el país.
2. **Políticas de Inclusión Digital:**
    1. Implementar políticas que promuevan la inclusión digital, especialmente en áreas rurales y marginalizadas, para reducir la brecha digital y asegurar que más personas puedan beneficiarse del acceso a internet.
3. **Monitoreo y Adaptación:**
    1. Continuar monitoreando las tendencias de crecimiento y adaptar las estrategias comerciales y de expansión según las necesidades y demandas del mercado para mantener el crecimiento y la estabilidad del sector.

Estos puntos ofrecen una visión más completa del panorama actual y futuro del acceso a internet en la región, y destacan la importancia de seguir innovando y adaptando las estrategias para aprovechar al máximo las oportunidades del mercado.

7.0.6 Referencias bibliográficas y herramientas utilizadas

Fuentes de datos y artículos:

1. **Internet Fijo Penetración Departamentos - Datos Abiertos de Colom-**

bia URL: https://www.datos.gov.co/Ciencia-Tecnolog-a-e-Innovaci-n/Internet-Fijo-Penetraci-n-Departamentos/4py7-br84/about_data
2. **MNIST Dataset - TensorFlow** URL: https://www.tensorflow.org/datasets/catalog/mnist?hl=es-419
3. **Bank Loan Classification - Kaggle** URL: https://www.kaggle.com/code/abedi756/bank-loan-classification/input?select=B_practice.csv
4. **Introducción al modelo ARIMA - DataCamp** URL: (https://www.datacamp.com/es/tutorial/arima#:~:text=Un%20modelo%20ARIMA%20(Media%20M%C3%B3vil,afinar%20las%20predicciones%20(MA))
5. **Recurrent Neural Networks - IBM** URL: https://www.ibm.com/es-es/topics/recurrent-neural-networks
6. **Building a Recurrent Neural Network from Scratch - Medium** URL: https://medium.com/@thisislong/building-a-recurrent-neural-network-from-scratch-ba9b27a42856
7. **Ministerio de Salud - Biblioteca Digital** URL: https://www.minsalud.gov.co/sites/rid/Lists/BibliotecaDigital/RIDE
8. **Contexto Migratorio Bogotá 2024 - Ministerio de Salud** URL: https://www.minsalud.gov.co/sites/rid/Lists/BibliotecaDigital/RIDE/INEC/INTOR/contexto-migratorio-bogota-2024.pdf #### **Herramientas empleadas:**
9. **Gemini**: Utilizado para realizar arreglos en funciones. e informacion critca
10. **Wordize**: Transformación de documentos Word a Markdown. URL: https://www.wordize.app/es/word-to-markdown/
11. **Visual Studio Code**: IDE utilizado para editar y subir código al repositorio.
12. **Repositorio en GitHub**: URL: https://github.com/jvergara9208/TalentoTec_Jonathan